

应用时间序列分析

子非鱼

目录

第一章 平稳序列	3
1.1 二阶平稳序列	3
1.2 白噪声与线性平稳序列	3
1.3 线性滤波	4
1.4 严平稳与遍历	4
1.5 谱函数与谱密度	5
第二章 AR 模型	6
2.1 p 阶常系数差分方程	6
2.2 $AR(p)$ 模型	6
2.3 Yule–Walker 方程	7
2.4 自协方差矩阵的正定性	8
2.5 线性预测	8
2.6 Levinson–Durbin 递推	8
2.7 $AR(2)$ 模型稳定区域	9
第三章 MA 与 ARMA 模型	10
3.1 $MA(q)$ 模型	10
3.2 $ARMA(p, q)$ 模型	10
第四章 数学期望与自协方差函数的估计	12
4.1 均值估计	12
4.2 样本自协方差与样本自相关	12
第五章 时间序列的预测	13
5.1 最佳线性预测	13
5.2 Hilbert 空间形式	13
5.3 Wold 分解	14
5.4 递推预测与正交分解	15
5.5 AR 、 MA 与 $ARMA$ 模型的预测	15

第六章 参数估计与定阶	17
6.1 AR 模型参数估计	17
6.1.1 Yule-Walker 估计	17
6.1.2 最小二乘估计	17
6.1.3 最大似然估计	17
6.2 AR 模型定阶	18
6.2.1 偏相关系数检验	18
6.2.2 AIC 与 BIC	18
6.3 MA 模型参数估计	18
6.3.1 矩估计	18
6.3.2 逆相关函数法	18
6.3.3 新息估计法	19
6.4 ARMA 模型参数估计	19
6.4.1 延伸的 Yule-Walker 方法	19
6.4.2 自回归逼近法	20
6.4.3 似然函数与创新表示	20
第七章 条件异方差模型	21
7.1 ARCH(p) 模型	21
7.2 GARCH(p, q) 模型	21
第八章 谱估计	22
8.1 周期图	22
8.2 加窗谱估计	22
第九章 多元时间序列分析	24
9.1 多元平稳序列	24
9.2 多维白噪声与线性平稳序列	25
9.3 多维 MA 模型	25

第一章 平稳序列

1.1 二阶平稳序列

定义 1.1 (二阶平稳). 随机序列 $\{X_t, t \in \mathbb{Z}\}$ 称为二阶平稳序列, 若满足:

1. $\mathbb{E}X_t^2 < \infty$;
2. $\mathbb{E}X_t = \mu$ 与 t 无关;
3. $\mathbb{E}[(X_t - \mu)(X_{t+k} - \mu)] = \gamma(k)$ 仅与时滞 k 有关。

其中 $\gamma(k)$ 称为自协方差函数, 标准化后得到自相关函数

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}, \quad \gamma(0) > 0.$$

命题 1.1 (自协方差函数的性质). 若 $\{X_t\}$ 二阶平稳, 则

1. $\gamma(0) \geq 0$, 且 $\gamma(k) = \gamma(-k)$;
2. $|\gamma(k)| \leq \gamma(0)$;
3. 对任意 n , Toeplitz 矩阵

$$\Gamma_n = (\gamma(i-j))_{i,j=1}^n$$

非负定, 即对任意 $a = (a_1, \dots, a_n)^\top$,

$$a^\top \Gamma_n a = \mathbb{E} \left(\sum_{j=1}^n a_j (X_j - \mu) \right)^2 \geq 0.$$

1.2 白噪声与线性平稳序列

定义 1.2 (白噪声). 若 $\{\varepsilon_t\}$ 二阶平稳, $\mathbb{E}\varepsilon_t = 0$, $\text{Var}(\varepsilon_t) = \sigma^2$, 且

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0, \quad t \neq s,$$

则称 $\{\varepsilon_t\}$ 为白噪声, 记为

$$\varepsilon_t \sim \text{WN}(0, \sigma^2).$$

定义 1.3 (线性平稳序列). 设 $\{\varepsilon_t\} \sim \text{WN}(0, \sigma^2)$, 若

$$\sum_{j=-\infty}^{\infty} |a_j| < \infty,$$

则

$$X_t = \sum_{j=-\infty}^{\infty} a_j \varepsilon_{t-j}$$

定义了一个二阶平稳序列, 称为线性平稳序列。

其均值为 0, 自协方差函数为

$$\gamma(k) = \sigma^2 \sum_{j=-\infty}^{\infty} a_j a_{j+k}.$$

由于 $\sum |a_j| < \infty$, 上述级数绝对收敛。

1.3 线性滤波

设 $\{X_t\}$ 是二阶平稳序列, 均值为 μ_X , 自协方差函数为 $\gamma_X(k)$ 。若 $\{h_j\} \in \ell^1$, 定义

$$Y_t = \sum_{j=-\infty}^{\infty} h_j X_{t-j},$$

则 $\{Y_t\}$ 仍为二阶平稳序列, 并且

$$\mu_Y = \mu_X \sum_{j=-\infty}^{\infty} h_j,$$

$$\gamma_Y(k) = \sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} h_i h_j \gamma_X(k + i - j).$$

1.4 严平稳与遍历

定义 1.4 (严平稳). 序列 $\{X_t\}$ 称为严平稳, 若对任意 n 、任意整数 $t_1, \dots, t_n$ 与任意平移 h ,

$$(X_{t_1}, \dots, X_{t_n}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_n+h}).$$

定理 1.1 (遍历定理). 若 $\{X_t\}$ 是平稳遍历序列, 且 $\mathbb{E}|X_0| < \infty$, 则

$$\frac{1}{n} \sum_{t=1}^n X_t \longrightarrow \mathbb{E}X_0, \quad \text{a.s.}$$

若 $\{X_t\}$ 严平稳遍历, 且 g 为可测函数, 则

$$Y_t = g(X_t, \dots, X_{t-m})$$

仍为严平稳遍历序列。特别地, 若 $\{\varepsilon_t\}$ 为独立同分布白噪声, 且 $\sum |a_j| < \infty$, 则线性过程

$$X_t = \sum_j a_j \varepsilon_{t-j}$$

为严平稳遍历序列。

1.5 谱函数与谱密度

定义 1.5 (谱函数). 设 $\{X_t\}$ 二阶平稳, 自协方差函数为 $\gamma(k)$ 。若存在右连续、单调不减函数 F , 通常取 $F(-\pi) = 0$, 使得

$$\gamma(k) = \int_{-\pi}^{\pi} e^{ik\lambda} dF(\lambda),$$

则称 F 为 $\{X_t\}$ 的谱函数。

若 F 绝对连续, $dF(\lambda) = f(\lambda) d\lambda$, 则称非负函数 f 为谱密度, 并有

$$\gamma(k) = \int_{-\pi}^{\pi} e^{ik\lambda} f(\lambda) d\lambda.$$

定理 1.2. 若 $\sum_{k=-\infty}^{\infty} |\gamma(k)| < \infty$, 则谱密度存在且

$$f(\lambda) = \frac{1}{2\pi} \sum_{k=-\infty}^{\infty} \gamma(k) e^{-ik\lambda} = \frac{1}{2\pi} \left\{ \gamma(0) + 2 \sum_{k=1}^{\infty} \gamma(k) \cos(k\lambda) \right\}.$$

第二章 AR 模型

2.1 p 阶常系数差分方程

考虑齐次差分方程

$$X_t = a_1 X_{t-1} + \cdots + a_p X_{t-p}.$$

记后移算子为 B , 即 $BX_t = X_{t-1}$ 。特征多项式为

$$A(z) = 1 - \sum_{j=1}^p a_j z^j,$$

则方程可写为

$$A(B)X_t = 0.$$

若 $A(z)$ 的根为 $z_1, \dots, z_s$, 其中 z_j 的重数为 m_j , 则通解可写为

$$X_t = \sum_{j=1}^s \sum_{\ell=0}^{m_j-1} c_{j\ell} t^\ell z_j^{-t}.$$

若所有根均在单位圆外, 即 $|z_j| > 1$, 则齐次解按指数阶收敛到 0。

对非齐次方程

$$A(B)X_t = Y_t,$$

其通解为 “一个特解 + 齐次通解”。

2.2 $AR(p)$ 模型

定义 2.1 ($AR(p)$). 设 $\{\varepsilon_t\} \sim WN(0, \sigma^2)$, $a_p \neq 0$, 并且

$$A(z) = 1 - \sum_{j=1}^p a_j z^j$$

的零点都在单位圆外。称

$$X_t = a_1 X_{t-1} + \cdots + a_p X_{t-p} + \varepsilon_t$$

为 $AR(p)$ 模型, 即

$$A(B)X_t = \varepsilon_t.$$

若 $A(z)$ 的零点在单位圆外, 则 $A^{-1}(z)$ 在某个包含闭单位圆的区域内解析, 可展开为

$$A^{-1}(z) = \sum_{j=0}^{\infty} \psi_j z^j, \quad \sum_{j=0}^{\infty} |\psi_j| < \infty.$$

于是 $AR(p)$ 的平稳因果解为

$$X_t = A^{-1}(B)\varepsilon_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}.$$

其自协方差函数为

$$\gamma(k) = \sigma^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+|k|},$$

谱密度为

$$f(\lambda) = \frac{\sigma^2}{2\pi} \frac{1}{|A(e^{-i\lambda})|^2}.$$

2.3 Yule–Walker 方程

由模型

$$X_t = a_1 X_{t-1} + \cdots + a_p X_{t-p} + \varepsilon_t$$

两边同乘 X_{t-k} 并取期望, 可得

$$\gamma(k) = a_1 \gamma(k-1) + \cdots + a_p \gamma(k-p), \quad k \geq 1,$$

其中当 $k=0$ 时有

$$\gamma(0) = a_1 \gamma(1) + \cdots + a_p \gamma(p) + \sigma^2.$$

写成矩阵形式:

$$\Gamma_p a = \gamma_p,$$

其中

$$\Gamma_p = \begin{pmatrix} \gamma(0) & \gamma(1) & \cdots & \gamma(p-1) \\ \gamma(1) & \gamma(0) & \cdots & \gamma(p-2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma(p-1) & \gamma(p-2) & \cdots & \gamma(0) \end{pmatrix}, \quad a = (a_1, \dots, a_p)^T, \quad \gamma_p = (\gamma(1), \dots, \gamma(p))^T.$$

并且

$$\sigma^2 = \gamma(0) - a^T \gamma_p.$$

2.4 自协方差矩阵的正定性

设 $\Gamma_n = (\gamma(i-j))_{i,j=1}^n$ 。在线性平稳序列的非退化情形中, Γ_n 通常正定。若谱密度 $f(\lambda)$ 在足够意义下为正, 则 Γ_n 正定。若谱函数只有有限个跳跃点, 则 Γ_n 的正定性可能受样本维数限制; 若有无限多个跳跃点, 通常可得到所有 Γ_n 正定。

2.5 线性预测

给定随机变量 Y 与向量 $X = (X_1, \dots, X_n)^\top$, 考虑

$$L(Y|X) = a_0 + a_1 X_1 + \dots + a_n X_n$$

使

$$\mathbb{E}(Y - a_0 - a^\top X)^2$$

最小。令 $\bar{Y} = Y - \mathbb{E}Y$ 、 $\bar{X} = X - \mathbb{E}X$, 设

$$\Sigma_X = \text{Var}(X), \quad \Sigma_{XY} = \mathbb{E}[\bar{X}\bar{Y}].$$

若 Σ_X 可逆, 则

$$a = \Sigma_X^{-1} \Sigma_{XY}, \quad a_0 = \mathbb{E}Y - a^\top \mathbb{E}X,$$

且最小误差为

$$\text{Var}(Y) - \Sigma_{XY}^\top \Sigma_X^{-1} \Sigma_{XY}.$$

对于零均值平稳序列,

$$L(X_{n+1} | X_n, \dots, X_1) = a_n^\top (X_n, \dots, X_1)^\top,$$

其中

$$a_n = \Gamma_n^{-1} \gamma_n, \quad \gamma_n = (\gamma(1), \dots, \gamma(n))^\top.$$

一步预测误差方差为

$$\sigma_n^2 = \gamma(0) - \gamma_n^\top \Gamma_n^{-1} \gamma_n.$$

2.6 Levinson–Durbin 递推

给定 Yule–Walker 方程

$$\Gamma_k a_k = \gamma_k, \quad k = 1, 2, \dots, n,$$

若 Γ_n 正定, 则可用递推求解。记

$$a_k = (a_{k,1}, \dots, a_{k,k})^\top, \quad \sigma_k^2 = \gamma(0) - a_k^\top \gamma_k.$$

初值为

$$a_{1,1} = \frac{\gamma(1)}{\gamma(0)}, \quad \sigma_1^2 = \gamma(0)(1 - a_{1,1}^2).$$

递推公式为

$$a_{k+1,k+1} = \frac{\gamma(k+1) - \sum_{j=1}^k a_{k,j} \gamma(k+1-j)}{\sigma_k^2},$$

$$a_{k+1,j} = a_{k,j} - a_{k+1,k+1} a_{k,k+1-j}, \quad j = 1, \dots, k,$$

$$\sigma_{k+1}^2 = \sigma_k^2 (1 - a_{k+1,k+1}^2).$$

推论 2.1. 零均值平稳序列为 $AR(p)$ 序列的一个重要判别特征是：偏自相关系数在 p 阶后截尾。

2.7 AR(2) 模型稳定区域

对

$$X_t = a_1 X_{t-1} + a_2 X_{t-2} + \varepsilon_t$$

而言，稳定性条件等价于特征多项式

$$1 - a_1 z - a_2 z^2$$

的零点均在单位圆外。常用不等式形式为

$$a_1 + a_2 < 1, \quad a_2 - a_1 < 1, \quad |a_2| < 1.$$

第三章 MA 与 ARMA 模型

3.1 MA(q) 模型

定义 3.1 (MA(q)). 设 $\{\varepsilon_t\} \sim \text{WN}(0, \sigma^2)$, 实数 $b_1, \dots, b_q$ 满足 $b_q \neq 0$ 。令

$$B(z) = 1 + \sum_{j=1}^q b_j z^j.$$

称

$$X_t = \varepsilon_t + b_1 \varepsilon_{t-1} + \dots + b_q \varepsilon_{t-q} = B(B)\varepsilon_t$$

为 MA(q) 模型。若 $B(z) = 0$ 的根均在单位圆外, 则称模型可逆。

MA(q) 的自协方差函数为

$$\gamma(k) = \begin{cases} \sigma^2 \sum_{j=0}^{q-k} b_j b_{j+k}, & 0 \leq k \leq q, \\ 0, & k > q, \end{cases}$$

其中 $b_0 = 1$, 且 $\gamma(-k) = \gamma(k)$ 。因此 MA(q) 的自协方差函数在 q 阶后截尾。

定理 3.1. 零均值平稳序列 $\{X_t\}$ 为 MA(q) 序列的一个典型判别条件是: 其自协方差函数在 q 阶后截尾, 即 $\gamma(k) = 0$ 对所有 $|k| > q$ 成立。

3.2 ARMA(p, q) 模型

定义 3.2 (ARMA(p, q)). 设 $\{\varepsilon_t\} \sim \text{WN}(0, \sigma^2)$,

$$A(z) = 1 - \sum_{j=1}^p a_j z^j, \quad B(z) = 1 + \sum_{j=1}^q b_j z^j,$$

且 $A(z)$ 与 $B(z)$ 无公共根, $a_p b_q \neq 0$ 。若 $A(z)$ 的零点均在单位圆外, 则称

$$A(B)X_t = B(B)\varepsilon_t$$

为 ARMA(p, q) 模型。

记

$$\Psi(z) = \frac{B(z)}{A(z)} = \sum_{j=0}^{\infty} \psi_j z^j.$$

在平稳因果条件下,

$$X_t = \Psi(B)\varepsilon_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j},$$

且

$$\gamma(k) = \sigma^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+|k|}.$$

谱密度为

$$f(\lambda) = \frac{\sigma^2 |B(e^{-i\lambda})|^2}{2\pi |A(e^{-i\lambda})|^2}.$$

对于 ARMA(p, q), 当 $k > q$ 时, 自协方差函数满足 AR 型递推:

$$\gamma(k) = a_1 \gamma(k-1) + \cdots + a_p \gamma(k-p), \quad k > q.$$

这就是延伸的 Yule-Walker 方程的核心形式。

第四章 数学期望与自协方差函数的估计

4.1 均值估计

设 $\{X_t\}$ 平稳, 均值为 μ 。样本均值

$$\bar{X}_N = \frac{1}{N} \sum_{t=1}^N X_t$$

是 μ 的无偏估计。若 $\gamma(k) \rightarrow 0$, 则

$$\bar{X}_N \xrightarrow{L^2} \mu, \quad \bar{X}_N \xrightarrow{P} \mu.$$

若 $\{X_t\}$ 严平稳遍历, 则

$$\bar{X}_N \longrightarrow \mu, \quad \text{a.s.}$$

在更强条件下, $\bar{X}_N$ 还满足中心极限定理与重对数律。

4.2 样本自协方差与样本自相关

常用样本自协方差估计量为

$$\hat{\gamma}(k) = \frac{1}{N} \sum_{t=1}^{N-k} (X_t - \bar{X}_N)(X_{t+k} - \bar{X}_N), \quad 0 \leq k \leq N-1.$$

令 $\hat{\gamma}(-k) = \hat{\gamma}(k)$ 。样本自相关系数定义为

$$\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)}.$$

样本自协方差矩阵为

$$\hat{\Gamma}_n = (\hat{\gamma}(i-j))_{i,j=1}^n.$$

若观测值 $X_1, \dots, X_N$ 不全相同, 则 $\hat{\Gamma}_n$ 非负定; 在适当维数条件下可为正定。

定理 4.1 (相合性). 对固定 k :

1. 若 $\gamma(k) \rightarrow 0$, 则 $\hat{\gamma}(k)$ 是 $\gamma(k)$ 的渐近无偏估计;
2. 若序列严平稳遍历, 则 $\hat{\gamma}(k)$ 与 $\hat{\rho}(k)$ 是强相合估计。

第五章 时间序列的预测

5.1 最佳线性预测

定义 5.1. 给定 Y 与 $X = (X_1, \dots, X_n)^\top$, 若

$$\hat{Y} = a_0 + a^\top X$$

使

$$\mathbb{E}(Y - \hat{Y})^2$$

在所有线性函数中达到最小, 则称 $\hat{Y}$ 为 Y 关于 $X_1, \dots, X_n$ 的最佳线性预测, 记为

$$\hat{Y} = L(Y|X_1, \dots, X_n).$$

若非零均值, 可将变量中心化:

$$L(Y|X) = \mathbb{E}Y + L(Y - \mathbb{E}Y | X - \mathbb{E}X).$$

设

$$P = \mathbb{E}(XX^\top), \quad c = \mathbb{E}(XY).$$

若 P 可逆, 则

$$L(Y|X) = a^\top X, \quad a = P^{-1}c.$$

若 P 不可逆, 则正规方程

$$Pa = c$$

仍给出预测系数, 但解可能不唯一; 对应的预测随机变量唯一。

残差满足正交性:

$$\mathbb{E}\{[Y - L(Y|X)]X_i\} = 0, \quad i = 1, \dots, n.$$

5.2 Hilbert 空间形式

设 L^2 为平方可积随机变量构成的 Hilbert 空间, 内积为

$$\langle X, Y \rangle = \mathbb{E}(XY).$$

若 H 是闭子空间, 则 Y 在 H 上的最佳线性预测为正交投影:

$$L(Y|H) = \arg \min_{Z \in H} \mathbb{E}(Y - Z)^2.$$

其特征为

$$Y - L(Y|H) \perp H.$$

常用性质包括:

1. 线性性:

$$L(aX + bY|H) = aL(X|H) + bL(Y|H).$$

2. 若 $Y \in H$, 则 $L(Y|H) = Y$;

3. 若 $Y \perp H$, 则 $L(Y|H) = 0$;

4. 若 $H \subset M$, 则投影满足

$$P_H P_M = P_M P_H = P_H.$$

若 $(X_1, \dots, X_n, Y)$ 联合正态, 则最佳线性预测与条件期望一致, 即

$$L(Y|X_1, \dots, X_n) = \mathbb{E}(Y|X_1, \dots, X_n).$$

5.3 Wold 分解

令

$$H_t = \overline{\text{span}}\{X_t, X_{t-1}, \dots\}.$$

定义一步预测误差方差

$$\sigma_t^2 = \mathbb{E}[X_t - L(X_t|H_{t-1})]^2.$$

若 $\sigma_t^2 = 0$, 称序列为决定性序列; 若 $\sigma_t^2 > 0$, 称为非决定性序列; 若其决定性部分为零, 则称为纯非决定性序列。

定理 5.1 (Wold 表示定理). 任意零均值、非决定性平稳序列可表示为

$$X_t = \sum_{j=0}^{\infty} a_j \varepsilon_{t-j} + V_t, \quad a_0 = 1,$$

其中

$$\varepsilon_t = X_t - L(X_t|H_{t-1}), \quad \{\varepsilon_t\} \sim \text{WN}(0, \sigma^2),$$

并且 $\{\varepsilon_t\}$ 与过去正交, $\{V_t\}$ 为决定性平稳序列。若 $V_t = 0$, 则 $\{X_t\}$ 为纯非决定性序列。

若 $\{X_t\}$ 有谱密度 f , 则纯非决定性的一个重要判据为 Kolmogorov 条件:

$$\int_{-\pi}^{\pi} \log f(\lambda) d\lambda > -\infty.$$

相应一步预测误差方差为

$$\sigma^2 = 2\pi \exp \left\{ \frac{1}{2\pi} \int_{-\pi}^{\pi} \log f(\lambda) d\lambda \right\}.$$

5.4 递推预测与正交分解

设 $\{Y_t\}$ 是零均值序列, 令

$$L_n = \text{span}\{Y_1, \dots, Y_n\}.$$

定义

$$\hat{Y}_n = L(Y_n | L_{n-1}), \quad W_n = Y_n - \hat{Y}_n, \quad v_n = \mathbb{E}W_n^2.$$

则

$$L_n = \text{span}\{W_1, \dots, W_n\},$$

且

$$\mathbb{E}(W_i W_j) = 0, \quad i \neq j.$$

因此可将预测写成

$$L(Y_{n+1} | L_n) = \sum_{j=1}^n \theta_{n,j} W_j, \quad \theta_{n,j} = \frac{\mathbb{E}(Y_{n+1} W_j)}{v_j}.$$

预测误差方差为

$$v_{n+1} = \mathbb{E}Y_{n+1}^2 - \sum_{j=1}^n \theta_{n,j}^2 v_j.$$

5.5 AR、MA 与 ARMA 模型的预测

AR 模型

对

$$X_t = \sum_{j=1}^p a_j X_{t-j} + \varepsilon_t$$

若 $n \geq p$, 则

$$\hat{X}_{n+1|n} = L(X_{n+1} | L_n) = \sum_{j=1}^p a_j X_{n+1-j}.$$

多步预测递推为

$$\hat{X}_{n+k|n} = \sum_{j=1}^p a_j \hat{X}_{n+k-j|n},$$

其中当 $n+k-j \leq n$ 时, $\hat{X}_{n+k-j|n} = X_{n+k-j}$.

MA 模型

若

$$X_t = \varepsilon_t + \sum_{j=1}^q b_j \varepsilon_{t-j},$$

且已由递推得到历史创新 $\varepsilon_n, \varepsilon_{n-1}, \dots$, 则

$$\hat{X}_{n+1|n} = \sum_{j=1}^q b_j \varepsilon_{n+1-j}.$$

更一般地,

$$\hat{X}_{n+k|n} = \sum_{j=k}^q b_j \varepsilon_{n+k-j}, \quad 1 \leq k \leq q,$$

而当 $k > q$ 时 $\hat{X}_{n+k|n} = 0$ (零均值情形)。

ARMA 模型

对

$$X_t = \sum_{j=1}^p a_j X_{t-j} + \varepsilon_t + \sum_{j=1}^q b_j \varepsilon_{t-j},$$

多步预测可按递推式计算:

$$\hat{X}_{n+k|n} = \sum_{j=1}^p a_j \hat{X}_{n+k-j|n} + \sum_{j=k}^q b_j \hat{\varepsilon}_{n+k-j},$$

其中 $\hat{X}_t = X_t$ 、 $\hat{\varepsilon}_t = \varepsilon_t$ 对 $t \leq n$, 而未来创新的条件预测为 0。

第六章 参数估计与定阶

6.1 AR 模型参数估计

6.1.1 Yule–Walker 估计

令

$$Y_t = X_t - \bar{X}, \quad \hat{\gamma}(k) = \frac{1}{N} \sum_{t=1}^{N-k} Y_t Y_{t+k}.$$

由 Yule–Walker 方程解出

$$\hat{\Gamma}_p \hat{a} = \hat{\gamma}_p.$$

于是

$$\hat{a} = \hat{\Gamma}_p^{-1} \hat{\gamma}_p, \quad \hat{\sigma}^2 = \hat{\gamma}(0) - \hat{a}^\top \hat{\gamma}_p.$$

在稳定性条件下，该估计通常强相合。

6.1.2 最小二乘估计

最小化残差平方和

$$S(a_1, \dots, a_p) = \sum_{t=p+1}^N (Y_t - a_1 Y_{t-1} - \dots - a_p Y_{t-p})^2.$$

由正规方程即可求解。在线性 AR 模型的常规条件下，OLS 估计强相合。手写笔记中还记录：OLS 与 Yule–Walker 估计之差为小量，量级约为 $O_p(N^{-1})$ 。

6.1.3 最大似然估计

在正态性假设下，可考虑条件似然

$$L(a, \sigma^2) \propto (\sigma^2)^{-(N-p)/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{t=p+1}^N \left(Y_t - \sum_{j=1}^p a_j Y_{t-j} \right)^2 \right\}.$$

最大化该条件似然得到的 a 与 OLS 估计一致； σ^2 可由残差平方和估计。

6.2 AR 模型定阶

6.2.1 偏相关系数检验

若真实模型为 $AR(p)$, 则对 $k > p$, 偏自相关系数近似满足

$$\sqrt{N} \hat{a}_{k,k} \xrightarrow{d} N(0, 1).$$

因此可用阈值 $\pm 1.96/\sqrt{N}$ 对偏自相关函数进行截尾判断。

6.2.2 AIC 与 BIC

对候选阶数 k , 若残差方差估计为 $\hat{\sigma}_k^2$, 则

$$AIC(k) = \log \hat{\sigma}_k^2 + \frac{2k}{N},$$

$$BIC(k) = \log \hat{\sigma}_k^2 + \frac{k \log N}{N}.$$

选择使准则最小的阶数作为估计。

6.3 MA 模型参数估计

6.3.1 矩估计

对 $MA(q)$,

$$\gamma(k) = \sigma^2 \sum_{j=0}^{q-k} b_j b_{j+k}, \quad k = 0, \dots, q.$$

将 $\gamma(k)$ 替换为 $\hat{\gamma}(k)$, 可解出 $b_1, \dots, b_q$ 与 σ^2 。但该方法不能保证解唯一, 也不能保证可逆性。

6.3.2 逆相关函数法

给定 $\{X_t\}$ 的谱密度 $f_X(\lambda)$, 可定义逆谱密度

$$f_Y(\lambda) = \frac{1}{4\pi^2 f_X(\lambda)},$$

并定义逆相关函数

$$\gamma_Y(k) = \int_{-\pi}^{\pi} e^{ik\lambda} f_Y(\lambda) d\lambda.$$

对于可逆 $MA(q)$ 序列, 可将其写成无限阶 AR 形式:

$$X_t - \sum_{j=1}^{\infty} a_j X_{t-j} = \varepsilon_t.$$

实际估计时, 取长阶 p 的 AR 近似来估计逆相关函数, 再利用 Yule-Walker 方程估计 $b_1, \dots, b_q$ 。

估计流程可概括为:

1. 利用 $\{X_t\}$ 建立高阶 $AR(p_N)$ 模型, 得到 $\hat{a}_1, \dots, \hat{a}_{p_N}$ 与 $\hat{\sigma}_p^2$;
2. 计算逆相关函数估计, 例如

$$\hat{\gamma}_Y(k) = \frac{1}{\hat{\sigma}_p^2} \sum_{j=0}^{p_N-k} \hat{a}_j \hat{a}_{j+k}, \quad \hat{a}_0 = 1;$$

3. 对 $\hat{\gamma}_Y(k)$ 使用 Yule-Walker 方程求出 $MA(q)$ 参数。

6.3.3 新息估计法

设

$$\varepsilon_{t+1} = X_{t+1} - L(X_{t+1}|X_t, X_{t-1}, \dots).$$

利用创新算法可得到近似创新 $\hat{\varepsilon}_t$ 。对

$$X_t = \varepsilon_t + b_1 \varepsilon_{t-1} + \dots + b_q \varepsilon_{t-q},$$

可用创新序列估计 b_j 。手写笔记中记录了“通常取 m 充分大”的做法, 即用较长历史的创新递推稳定后再取参数估计。

6.4 ARMA 模型参数估计

6.4.1 延伸的 Yule-Walker 方法

由延伸的 Yule-Walker 方程,

$$\gamma(k) = \sum_{j=1}^p a_j \gamma(k-j), \quad k > q,$$

可取 $k = q+1, \dots, q+p$ 构造线性方程组:

$$\begin{pmatrix} \gamma(q) & \gamma(q-1) & \cdots & \gamma(q-p+1) \\ \gamma(q+1) & \gamma(q) & \cdots & \gamma(q-p+2) \\ \vdots & \vdots & \ddots & \vdots \\ \gamma(q+p-1) & \gamma(q+p-2) & \cdots & \gamma(q) \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix} = \begin{pmatrix} \gamma(q+1) \\ \gamma(q+2) \\ \vdots \\ \gamma(q+p) \end{pmatrix}.$$

用 $\hat{\gamma}(k)$ 替换 $\gamma(k)$ 可得到 a 的矩估计。得到 $\hat{a}$ 后, 令

$$Z_t = X_t - \sum_{j=1}^p \hat{a}_j X_{t-j},$$

再使用前述 MA 模型估计方法估计 b 。

6.4.2 自回归逼近法

先给出高阶 AR 模型估计残差

$$\hat{Z}_t = X_t - \sum_{j=1}^m \hat{\phi}_j X_{t-j}.$$

然后用 OLS 最小化

$$Q(a, b) = \sum_{t=\ell+1}^N \left(X_t - \sum_{j=1}^p a_j X_{t-j} - \sum_{j=1}^q b_j \hat{Z}_{t-j} \right)^2, \quad \ell = \max(p, q).$$

6.4.3 似然函数与创新表示

令 $X_n = (X_1, \dots, X_n)^\top$ 。通过创新递推可写成

$$X_n = CZ_n,$$

其中

$$D = \mathbb{E}(Z_n Z_n^\top) = \text{diag}(r_0, r_1, \dots, r_{n-1}),$$

于是

$$\Gamma_n = \mathbb{E}(X_n X_n^\top) = CDC^\top, \quad \det \Gamma_n = r_0 r_1 \cdots r_{n-1}.$$

若服从正态分布, 则似然函数可写为

$$L(\theta) = (2\pi)^{-n/2} |\Gamma_n|^{-1/2} \exp \left\{ -\frac{1}{2} X_n^\top \Gamma_n^{-1} X_n \right\}$$

或等价地写成创新形式

$$L(\theta) = (2\pi)^{-n/2} (r_0 \cdots r_{n-1})^{-1/2} \exp \left\{ -\frac{1}{2} \sum_{j=0}^{n-1} \frac{z_j^2}{r_j} \right\}.$$

若 $r_j = \sigma^2 v_j(\beta)$, 则对 σ^2 求极值得

$$\hat{\sigma}^2 = \frac{1}{N} S(\beta), \quad S(\beta) = \sum_{j=0}^{N-1} \frac{z_j^2}{v_j(\beta)}.$$

代回可得到关于 β 的集中似然; 忽略常数项后可极小化

$$\log \left(\frac{S(\beta)}{N} \right) + \frac{1}{N} \sum_{j=0}^{N-1} \log v_j(\beta).$$

第七章 条件异方差模型

7.1 ARCH(p) 模型

定义 7.1 (ARCH(p)). 设 $\{\eta_t\}$ 为独立同分布标准白噪声, $\alpha_0 > 0$, $\alpha_i \geq 0$, 并满足

$$\sum_{i=1}^p \alpha_i < 1.$$

若

$$\varepsilon_t = \sigma_t \eta_t,$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \cdots + \alpha_p \varepsilon_{t-p}^2,$$

且 η_t 与过去 $\{\varepsilon_{t-1}, \varepsilon_{t-2}, \dots\}$ 独立, 则称 $\{\varepsilon_t\}$ 为 ARCH(p) 模型。

7.2 GARCH(p, q) 模型

定义 7.2 (GARCH(p, q)). 设 $\{\eta_t\}$ 为独立同分布标准白噪声, $\alpha_0 > 0$, $\alpha_i \geq 0$, $\beta_j \geq 0$, 并满足

$$\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j < 1.$$

若

$$\varepsilon_t = \sigma_t \eta_t,$$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2,$$

且 η_t 与过去信息独立, 则称其为 GARCH(p, q) 模型。

第八章 谱估计

8.1 周期图

给定观测 $X_1, \dots, X_N$, 令

$$\bar{X} = \frac{1}{N} \sum_{k=1}^N X_k,$$

$$\hat{\gamma}(k) = \frac{1}{N} \sum_{t=1}^{N-k} (X_t - \bar{X})(X_{t+k} - \bar{X}), \quad 0 \leq k < N.$$

一种谱密度估计为

$$\hat{f}_N(\lambda) = \frac{1}{2\pi} \sum_{k=-(N-1)}^{N-1} \hat{\gamma}(k) e^{-ik\lambda}.$$

定义有限 Fourier 变换

$$J_N(\lambda) = \frac{1}{\sqrt{2\pi N}} \sum_{k=1}^N (X_k - \bar{X}) e^{-ik\lambda}.$$

周期图定义为

$$I_N(\lambda) = |J_N(\lambda)|^2 = \frac{1}{2\pi N} \left| \sum_{k=1}^N (X_k - \bar{X}) e^{-ik\lambda} \right|^2.$$

在 Fourier 频率

$$\lambda_j = \frac{2\pi j}{N}, \quad j = 0, 1, \dots, N-1,$$

有

$$I_N(\lambda_j) = \hat{f}_N(\lambda_j).$$

周期图是 $f(\lambda)$ 的渐近无偏估计, 但通常并不相合。

8.2 加窗谱估计

为克服周期图不相合性, 引入时窗 $\{\lambda_N(k)\}$, 定义

$$\hat{f}(\lambda) = \frac{1}{2\pi} \sum_{k=-(N-1)}^{N-1} \lambda_N(k) \hat{\gamma}(k) e^{-ik\lambda}.$$

相应谱窗定义为

$$W_N(\lambda) = \frac{1}{2\pi} \sum_{k=-(N-1)}^{N-1} \lambda_N(k) e^{-ik\lambda}.$$

则时窗与谱窗一一对应:

$$W_N(\lambda) = \frac{1}{2\pi} \sum_{k=-(N-1)}^{N-1} \lambda_N(k) e^{-ik\lambda},$$

$$\lambda_N(k) = \int_{-\pi}^{\pi} W_N(\lambda) e^{ik\lambda} d\lambda.$$

并且加窗估计可写成周期图的平滑形式:

$$\hat{f}(\lambda) = \int_{-\pi}^{\pi} I_N(s) W_N(\lambda - s) ds.$$

第九章 多元时间序列分析

9.1 多元平稳序列

定义 9.1 (多元平稳序列). 设

$$X_t = (X_{t1}, \dots, X_{tm})^T.$$

若对任意 t :

1. $\mathbb{E}X_t = \mu = (\mu_1, \dots, \mu_m)^T$ 与 t 无关;

2.

$$\Gamma(h) = \mathbb{E}\{(X_{t+h} - \mu)(X_t - \mu)^T\}$$

仅与滞后 h 有关,

则称 $\{X_t\}$ 为 m 维平稳序列。

记

$$\gamma_{jk}(h) = \mathbb{E}\{(X_{t+h,j} - \mu_j)(X_{t,k} - \mu_k)\}.$$

自相关系数为

$$\rho_{jk}(h) = \frac{\gamma_{jk}(h)}{\sqrt{\gamma_{jj}(0)\gamma_{kk}(0)}}.$$

多元自协方差矩阵满足:

1.

$$\Gamma(-h) = \Gamma(h)^T;$$

2.

$$|\gamma_{jk}(h)| \leq \sqrt{\gamma_{jj}(0)\gamma_{kk}(0)};$$

3. 对任意 $a_1, \dots, a_n \in \mathbb{R}^m$ 与整数 $t_1, \dots, t_n$,

$$\sum_{i=1}^n \sum_{j=1}^n a_i^T \Gamma(t_i - t_j) a_j \geq 0.$$

9.2 多维白噪声与线性平稳序列

若

$$\mathbb{E}\varepsilon_t = 0, \quad \mathbb{E}(\varepsilon_t \varepsilon_t^\top) = Q, \quad \mathbb{E}(\varepsilon_t \varepsilon_s^\top) = 0 \quad (t \neq s),$$

则称 $\{\varepsilon_t\}$ 为多维白噪声, 记为

$$\varepsilon_t \sim \text{WN}(0, Q).$$

若

$$X_t = \sum_{j=-\infty}^{\infty} G_j \varepsilon_{t-j}, \quad \sum_{j=-\infty}^{\infty} \|G_j\| < \infty,$$

则 $\{X_t\}$ 为多维线性平稳序列, 且

$$\Gamma(h) = \sum_{j=-\infty}^{\infty} G_{j+h} Q G_j^\top.$$

9.3 多维 MA 模型

设 $\varepsilon_t \sim \text{WN}(0, Q)$, 定义

$$X_t = \varepsilon_t + B_1 \varepsilon_{t-1} + \cdots + B_q \varepsilon_{t-q}.$$

若

$$\det(I + B_1 z + \cdots + B_q z^q) \neq 0, \quad |z| < 1,$$

则该多维 MA(q) 模型可逆。原稿最后一页对应的公式为

$$X_t = \varepsilon_t + \sum_{j=1}^q B_j \varepsilon_{t-j}.$$