

On the Algorithmic Bias of Aligning Large Language Models with RLHF: Preference Collapse and Matching Regularization

(基于 RLHF 大语言模型对齐算法偏误研究：偏好崩溃与匹配正则化)

毛志远 张渊

北京大学数学科学学院 北京大学国家发展研究院

《深度学习与文本分析》期末论文汇报

1. Introduction (引言: 偏好坍塌为什么重要)
2. Preliminaries (预备知识: LLM 与标准 RLHF)
3. From KL-RLHF to PM Regularization (从 KL-RLHF 到偏好匹配正则)
4. Conditional PM RLHF (条件偏好匹配 RLHF)
5. Evaluation and Experiments (评价指标与实验结果)
6. Discussion (余论)

1. Introduction (引言: 偏好坍塌为什么重要)

- 1.1 Motivation (为什么偏好分布重要)
- 1.2 Algorithmic Bias (KL-RLHF 为什么会混入先验偏差)
- 1.3 Preference Collapse (从偏好压缩到偏好坍塌)
- 1.4 Contributions and Open Challenge (本文贡献与未解问题)

1.1 Motivation (为什么偏好分布重要)

LLM 不只是在生成文本，也越来越多地进入推荐、评价、调研、模拟用户意见和辅助决策等场景。在这些任务中，模型输出往往会被使用者理解为一种“人群偏好”的近似。

如果问题有标准答案

对齐目标可以接近“答对”：

$$y^* = \arg \max_y \text{quality}(x, y).$$

例如事实问答、代码修复、数学推理。

如果问题涉及偏好

对齐目标应接近“保留比例”：

$$\pi(y|x) \approx p_{\text{human}}(y|x).$$

例如电影推荐、菜单选择、观点表达。

核心问题：当 RLHF 被用于偏好型任务时，模型是否真的保留了人类偏好分布？

1.1 Motivation (为什么偏好分布重要)

人类偏好天然有异质性。

文化背景、个人经历、使用场景不同，都会造成偏好差异。即使是训练过的标注者，也存在明显分歧：

annotator-annotator disagreement = 37%,

annotator-researcher disagreement = 23%.

对开放式任务来说，少数偏好不是噪声，而是偏好分布的一部分。真正重要的不是只知道谁赢，而是知道赢多少：

$90 : 10 \neq 60 : 40 \neq 20 : 80$.

餐厅菜单的直觉

顾客在“素食菜”和“辣味肉菜”之间是 90/10 还是 20/80，会导向完全不同的商业决策。LLM 若用于推荐或模拟人群意见，也需要保留这种比例信息。

1.1 Motivation (为什么偏好分布重要)

已有偏好偏置：模型容易偏向主流表达

已有研究观察到，LLM 表达偏好时，常常偏向训练语料中更频繁、更主流、更容易被模板化表达的选择。

- 高频项目更容易被推荐，低频项目更容易被忽略。
- 模型生成的观点分布可能高度偏向 dominant viewpoints。
- 在一些设置中，主流观点甚至会得到超过 99% 的模型概率。

“多数意见” 可能来自 训练数据频率 + 对齐目标塑形。

问题不是模型不会给少数答案，而是对齐后它可能更少给少数答案。

1.2 大模型的问题：Preference Collapse

Preference collapse 指的是：模型输出分布坍塌到少数狭窄路径上，少数偏好被严重压缩，极端时概率接近 0。

我们关心的不是“哪个回答赢了”，而是模型是否把真实偏好比例保存下来：

$$p_{\text{reward}}(y_1) = 0.6, \quad p_{\text{reward}}(y_2) = 0.4.$$

如果最后模型几乎永远输出 y_1 ，那么 y_2 代表的 40% 少数偏好就被抹掉了。

直观来看

偏好坍塌不是“少数偏好输了”，而是少数偏好在模型输出分布中被压到几乎不可见。

1.2 大模型的问题: Preference Collapse

Prompt: “推荐一部适合周末晚上看的电影。”

回答	风格	真实偏好	reference 先验
$y_1 = \text{《盗梦空间》}$	热门、科幻、烧脑、讨论度高	0.6	0.9
$y_2 = \text{《帕特森》}$	小众、慢节奏、文艺片	0.4	0.1

两个分布的含义不同:

$$p_{\text{reward}}(y_1, y_2) = (0.6, 0.4), \quad p_{\text{ref}}(y_1, y_2) = (0.9, 0.1).$$

关键: reward model 表示人类偏好; reference model 表示旧模型的生成习惯。标准 KL-RLHF 会同时听到这两个声音。

1.2 大模型的问题：Preference Collapse（直观示例）

参考模型偏向《盗梦空间》并不奇怪：热门大片在网络语料、影评、推荐列表中更常出现，SFT 数据也可能更偏向“安全、主流、容易被认可”的回答。

因而 reference model 可能已经具有强先验：

$$\pi_{\text{ref}}(y_1|x) = 0.9, \quad \pi_{\text{ref}}(y_2|x) = 0.1.$$

但真实人类偏好只是略偏向 y_1 ：

$$p_{\text{reward}}(y_1) = 0.6, \quad p_{\text{reward}}(y_2) = 0.4.$$

1.2 大模型的问题：Preference Collapse

Algorithmic Bias

标准 RLHF 表面上是在用 reward model 对齐人类偏好，但优化目标里还有 reference model。二者都在影响最终策略：

$$\underbrace{r(x, y)}_{\text{人类偏好信号}} \quad \underbrace{\pi_{\text{ref}}(y|x)}_{\text{旧模型生成习惯}} .$$

算法偏差结果：偏好坍塌风险

如果优化目标把这两种偏好叠加，轻微的人类多数偏好会和强烈的模型先验耦合，最终变成极端输出倾向。

1.3 本文贡献

1. 揭示标准 KL-RLHF 的内在算法偏差。
2. 指出极端情况下会出现 preference collapse。
3. 提出 Preference Matching (PM) RLHF。
4. 推导出 PM regularizer 的核心形式：

$$R(\pi) = -\log \pi(y|x).$$

5. 针对自然语言生成提出 conditional PM RLHF。
6. 在 OPT 与 Llama-family 模型上实验, PM divergence 相比标准 RLHF 改善约 29% 到 41%。

1.3 本文贡献

已有解释常把偏差归因于：

- 单一 reward function 难以表达复杂人类偏好；
- reward model 训练数据有限，可能 underfit 或 overfit；
- 标注团队本身可能不代表完整人群。

本文的研究强调另一层原因：

即使 $r_{\theta}(x, y) = r^{\star}(x, y)$, KL-RLHF 仍可能因 π_{ref} 产生偏差。

1.4* 拓展：开放挑战与前沿探索

截至 2026 年 6 月：偏好坍塌仍是开放挑战

- OpenAI 的 GPT-5 system card 强调改进 instruction following、降低 hallucination，并减少 sycophancy。
- OpenAI 2025 年 GPT-4o 复盘显示：一次更新曾使模型更 sycophantic，之后被回滚并加入更多行为评估。
- Anthropic Claude 4.1 system card 也把 sycophancy 与 reward hacking 作为持续评估对象。

preference collapse $\neq$ sycophancy.

两条探索路线

1. 在 RLHF 框架内改进

- 更好的 reference model;
- 数据选择与混合偏好优化，例如 MPO;
- 更细粒度的 reward signal 与行为评估。

2. 改变偏好优化范式

- DPO：用偏好数据直接优化策略;
- PM RLHF;
- 多目标 reward、群体偏好建模等方向。

偏好坍塌尚未被攻克；研究正在从“赢率最大化”转向“偏好分布保真”。

2. Preliminaries (预备知识: LLM 与标准 RLHF)

- 2.1 Language Model Probabilities (文本生成概率)
- 2.2 Reward Modeling (从人类比较到奖励函数)
- 2.3 KL-RLHF Objective (标准 RLHF 的优化目标)
- 2.4 Closed-form Bias (闭式解中的偏差放大机制)

2.1 Language Model Probabilities (文本生成概率)

给定 prompt x , LLM 不是一次性生成整段回答, 而是逐个预测 token。若回答为

$$y = [T_1, T_2, \dots, T_L],$$

则整段回答概率为:

$$\pi_{\phi}(y|x) = \prod_{i=1}^L \pi_{\phi}(T_i | T_{i-1}, \dots, T_1, x).$$

对数形式更常用于训练与分析:

$$\log \pi_{\phi}(y|x) = \sum_{i=1}^L \log \pi_{\phi}(T_i | T_{i-1}, \dots, T_1, x).$$

直觉: 回答概率是很多 token 概率相乘; 这会让“长短差异”也进入 reference model 的偏好结构。

2.1 Language Model Probabilities (文本生成概率)

长度偏差

如果每个 token 的平均条件概率约为 $q < 1$ ，长度为 L 的回答概率大约满足：

$$\pi_{\text{ref}}(y|x) \approx q^L.$$

因而两个回答长度差异较大时，reference odds 可能非常极端：

$$\frac{\pi_{\text{ref}}(y_{\text{short}}|x)}{\pi_{\text{ref}}(y_{\text{long}}|x)} \approx q^{L_{\text{short}} - L_{\text{long}}}.$$

短回答偏差

$y_1 = \text{“Yes.”}$ ， $y_2 = \text{一个完整、有信息量的长句回答。}$

人类可能更喜欢信息充分的长回答，但 reference model 的序列概率可能更偏向极短回答。

2.2 标准 RLHF

标准 RLHF 过程:

$$\text{预训练模型} \xrightarrow{\text{SFT}} \pi_{\text{SFT}} \approx \pi_{\text{ref}} \xrightarrow{\text{人类比较数据}} r_{\theta}(x, y) \xrightarrow{\text{policy learning}} \pi_{\phi}.$$

阶段	数学对象	电影例子中的含义
SFT/reference	$\pi_{\text{ref}}(y x)$	旧模型偏向热门大片
reward modeling	$r_{\theta}(x, y)$	人类 60/40 偏好
KL-RLHF	$\pi_{\phi}(y x)$	最终模型输出概率

偏好坍塌不是某一步孤立造成的，而是reference 先验和 reward 偏好在第三步耦合后的结果。

2.2.1 标准 RLHF 的 Step 1

SFT 的作用

RLHF 通常从一个通用预训练语言模型开始，用高质量数据做监督微调：

$$\pi_{\text{pretrain}} \xrightarrow{\text{SFT}} \pi_{\text{SFT}}.$$

在后续 RLHF 中，参考模型通常取：

$$\pi_{\text{ref}} = \pi_{\text{SFT}}.$$

注意： π_{ref} 不是中性的，它已经包含预训练数据与 SFT 数据中的分布偏好。

2.2.1 标准 RLHF 的 Step 1

为什么 reference model 不是中性的？

参考模型通常是预训练或 SFT 模型：

$$\pi_{\text{ref}} = \pi_{\text{SFT}}.$$

它不可能对所有有效回答均匀分布：

$$\pi_{\text{ref}}(y_1|x) \neq \pi_{\text{ref}}(y_2|x)$$

通常是常态，而不是例外。

偏差来源

- 训练语料中主流内容更常见；
- 短回答与模板化回答概率可能更高；
- SFT 数据也可能偏向某些风格或答案类型。

2.2.1 标准 RLHF 的 Step 1: 举例

对 prompt

$x = \text{“推荐一部适合周末晚上看的电影。”}$

两个候选回答为：

$y_1 = \text{《盗梦空间》}, \quad y_2 = \text{《帕特森》}.$

如果 SFT 数据中热门大片更多，reference model 可能天然更喜欢 y_1 ：

$$p_{\text{ref}}(y_1|x) = 0.9, \quad p_{\text{ref}}(y_2|x) = 0.1.$$

直觉

π_{ref} 不是“真实人群偏好”，而是旧模型的生成习惯。后面的 KL 正则会把这种先验保留下来。

2.2.2 标准 RLHF 的 Step 2: Preference and Reward Modeling

给定 prompt x , SFT 模型生成回答对:

$$(y_1, y_2) \sim \pi_{\text{SFT}}.$$

人类标注者比较两个回答:

$$y_w \succ y_l,$$

其中 y_w 是 winner, y_l 是 loser。

目标: 训练 reward model

$$r_{\theta}(x, y)$$

来表示人类偏好。

电影例子

人类比较《盗梦空间》和《帕特森》，标注哪个更适合周末晚上看。

2.2.2 标准 RLHF 的 Step 2: BTL 偏好模型

标准 RLHF 常用 Bradley-Terry-Luce 模型：

$$P(y_1 \succ y_2 | x, y_1, y_2) = \frac{\exp(r(x, y_1))}{\exp(r(x, y_1)) + \exp(r(x, y_2))}. \quad (2.1)$$

电影例子中：

$$P(y_1 \succ y_2 | x, y_1, y_2) = 0.6, \quad P(y_2 \succ y_1 | x, y_1, y_2) = 0.4.$$

这意味着 reward model 学到 y_1 略优于 y_2 ，但不是 y_2 没有价值。

2.2.2 标准 RLHF 的 Step 2: BTL 偏好模型

在 BTL 模型中:

$$P(y_1 \succ y_2) = \sigma(r_1 - r_2), [\sigma(x) = \frac{1}{1 + e^{-x}}]$$

因此 reward 差异就是 preference odds 的对数:

$$r_1 - r_2 = \log \frac{P(y_1 \succ y_2)}{P(y_2 \succ y_1)}.$$

代入电影例子:

$$r_1 - r_2 = \log \frac{0.6}{0.4} \approx 0.405.$$

注意

将奖励模型学习到的人类偏好（例如 60/40）转换成一个可加性的“对数几率”形式，从而与参考模型的对数几率直接相加，用于后续解释标准 RLHF 中偏差放大的机制。正值表示偏向 y，数值越大偏向越强

2.2.2 标准 RLHF 的 Step 2: Reward model 的训练: 优化目标

收集比较数据:

$$D_{\text{comp}} = \{x_i, y_w^i, y_l^i\}_{i=1}^n.$$

训练 reward model 可看作二分类问题, 最小化负对数似然:

$$\min_{\theta} -\mathbb{E}_{(x, y_w, y_l) \sim D_{\text{comp}}} [\log \sigma(r_{\theta}(x, y_w) - r_{\theta}(x, y_l))], \quad (2.2)$$

其中

$$\sigma(u) = \frac{1}{1 + \exp(-u)}.$$

因此, 可训练出一个能够为任意回答打分的奖励模型, 在第三步 (RLHF 微调) 中作为优化目标, 指导语言模型向人类偏好对齐。

2.2.3 标准 RLHF 的 Step 3

A. 如果优化目标只最大化 expected reward:

$$\max_{\phi} \mathbb{E}_{y \sim \pi_{\phi}(\cdot|x)} r(x, y),$$

那么最优策略会把概率集中到最高 reward 的回答上。

在 60/40 的例子中:

$$r(x, y_1) > r(x, y_2),$$

只最大化 reward 可能导致:

$$\pi(y_1|x) = 1, \quad \pi(y_2|x) = 0.$$

这会直接抹掉少数偏好。

2.2.3 标准 RLHF 的 Step 3

在电影例子中，reward model 学到：

$$r_1 - r_2 \approx 0.405 > 0.$$

也就是说，《盗梦空间》略高于《帕特森》，但差异只对应：

$$60/40.$$

如果 policy learning 只最大化 reward，那么二元最优策略会变成：

$$\pi^*(y_1|x) = 1, \quad \pi^*(y_2|x) = 0.$$

直觉

无正则 reward maximization 会把“略高偏好”变成“唯一输出”。标准 RLHF 加入 KL 正则就是为了避免这种过度优化。

2.2.3 标准 KL-RLHF 目标函数

B. 标准 RLHF 优化：加入正则化项

$$\max_{\phi} \mathbb{E}_{y \sim \pi_{\phi}(\cdot|x)} \left[r(x, y) - \beta D_{\text{KL}}(\pi_{\phi}(y|x) \parallel \pi_{\text{ref}}(y|x)) \right]. \quad (2.3)$$

其中：

- $r(x, y)$: reward model 给出的偏好信号；
- π_{ref} : 参考模型，通常是 SFT 模型；
- $\beta > 0$: 控制策略偏离 reference model 的程度。
- 因此，模型不能只选最高奖励的回答，还保持一定的“保守性”，与参考模型的分布不会差太远。

2.2.3 标准 KL-RLHF 目标函数

KL 项可写为：

$$D_{\text{KL}}(\pi_{\phi}(y|x) \parallel \pi_{\text{ref}}(y|x)) = \mathbb{E}_{y \sim \pi_{\phi}(\cdot|x)} [\log \pi_{\phi}(y|x) - \log \pi_{\text{ref}}(y|x)] .$$

这意味着：

- 如果 π_{ϕ} 给某回答更高概率，但 π_{ref} 原本很低，KL 惩罚会变大；
- 如果 π_{ref} 原本偏向某类回答，KL 会鼓励 π_{ϕ} 保留这种偏向。

电影例子中，《帕特森》有 40% 的真实偏好，但 reference model 只给它 10%。

KL 正则化会“锁定”参考模型的先验分布，使得 RLHF 难以纠正参考模型中已有的偏见，从而把参考模型的偏差传递给了最终模型。

附录 B1 KL-RLHF 的闭式解与 Bias 放大

通过引入拉格朗日乘子对目标函数关于 $\pi(y|x)$ 求导并令导数为零，再结合概率归一化条件，解出标准 RLHF 的最优解：

$$\pi_{\text{rlhf}}(y|x) = \frac{\pi_{\text{ref}}(y|x) \exp(r(x, y)/\beta)}{\sum_j \pi_{\text{ref}}(y_j|x) \exp(r(x, y_j)/\beta)}. \quad (\text{B.1})$$

关键观察

π_{rlhf} 同时吸收了 $r(x, y)$ 和 $\pi_{\text{ref}}(y|x)$.

最终策略不是只跟 reward model 对齐，而是 reference model 概率和 reward 指数项的乘积再归一化（附录 B.1）。

附录 B1 KL-RLHF 的闭式解与 Bias 放大

定义二元条件概率：

$$p_{\text{rlhf}}(y_i) = \frac{\pi_{\text{rlhf}}(y_i|x)}{\pi_{\text{rlhf}}(y_1|x) + \pi_{\text{rlhf}}(y_2|x)}.$$

同理定义 $p_{\text{reward}}(y_i)$ 与 $p_{\text{ref}}(y_i)$ 。则：

$$p_{\text{rlhf}}(y_i) = \frac{p_{\text{ref}}(y_i)p_{\text{reward}}(y_i)}{p_{\text{ref}}(y_1)p_{\text{reward}}(y_1) + p_{\text{ref}}(y_2)p_{\text{reward}}(y_2)}, \quad i = 1, 2. \quad (\text{B.2})$$

只要 reference 不是 0.5/0.5，就会扭曲 reward 偏好。

附录 B1 KL-RLHF 的闭式解与 Bias 放大

设 $\beta = 1$ ，并代入：

$$p_{\text{reward}}(y_1) = 0.6, \quad p_{\text{reward}}(y_2) = 0.4, \quad p_{\text{ref}}(y_1) = 0.9, \quad p_{\text{ref}}(y_2) = 0.1.$$

分母为：

$$0.9 \times 0.6 + 0.1 \times 0.4 = 0.54 + 0.04 = 0.58.$$

因此：

$$p_{\text{rlhf}}(y_1) = \frac{0.54}{0.58} \approx 0.931, \quad p_{\text{rlhf}}(y_2) = \frac{0.04}{0.58} \approx 0.069.$$

原本 40% 喜欢《帕特森》的人并不少，但 KL-RLHF 后只剩 6.9% 的输出概率。

对电影推荐:

$$\log \frac{p_{\text{ref}}(y_1)}{p_{\text{ref}}(y_2)} = \log \frac{0.9}{0.1} \approx 2.197,$$

$$\log \frac{p_{\text{reward}}(y_1)}{p_{\text{reward}}(y_2)} = \log \frac{0.6}{0.4} \approx 0.405.$$

因此:

$$\log \frac{p_{\text{rlhf}}(y_1)}{p_{\text{rlhf}}(y_2)} = 2.197 + 0.405 = 2.602,$$

对应

$$p_{\text{rlhf}}(y_1) \approx 0.931, \quad p_{\text{rlhf}}(y_2) \approx 0.069.$$

附录 B.2: 极端情况 Preference Collapse

若参考模型偏差更大:

$$p_{\text{ref}}(y_1) = 0.99, \quad p_{\text{ref}}(y_2) = 0.01.$$

分母为:

$$0.99 \times 0.6 + 0.01 \times 0.4 = 0.594 + 0.004 = 0.598.$$

于是:

$$p_{\text{rlhf}}(y_1) = \frac{0.594}{0.598} \approx 0.9933, \quad p_{\text{rlhf}}(y_2) = \frac{0.004}{0.598} \approx 0.0067.$$

$$60/40 \implies 99.3/0.7.$$

附录 B.2: 极端情况 Preference Collapse

由公式 (B.2) 可知:

$$p_{\text{rlhf}}(y_i) = \frac{p_{\text{ref}}(y_i)p_{\text{reward}}(y_i)}{p_{\text{ref}}(y_1)p_{\text{reward}}(y_1) + p_{\text{ref}}(y_2)p_{\text{reward}}(y_2)}.$$

如果 $p_{\text{ref}}(y_i) = 0$, 则

$$p_{\text{rlhf}}(y_i) = 0.$$

如果 $p_{\text{ref}}(y_i) = 1$, 则

$$p_{\text{rlhf}}(y_i) = 1.$$

这就是少数偏好被完全排除的 preference collapse (附录 B.2)。

结果：三种分布对比

分布	《盗梦空间》 y_1	《帕特森》 y_2
真实/Reward 偏好	0.600	0.400
Reference 偏好	0.900	0.100
KL-RLHF 后	0.931	0.069
极端 Reference 后的 KL-RLHF	0.993	0.007

附录 A.2: 这是不是 reward model 的锅?

数据偏差和 reward model bias 确实存在

- 标注团队可能不代表完整人群;
- reward model 可能 underfit 或 overfit;
- 数据质量会影响 Step 2 的 reward learning。

但这里强调:

即使在理想条件下, reward model 能学到真实 reward:

$$r_{\theta}(x, y) \approx r^{\star}(x, y),$$

标准 KL-RLHF 仍会因为 π_{ref} 引入算法偏差 (附录 A.2)。

附录 A.3: β 的影响

标准 KL-RLHF 中:

$$\pi_{\text{rlhf}}(y|x) \propto \pi_{\text{ref}}(y|x) \exp(r(x, y)/\beta).$$

β 控制 reward 差异的放大程度。

- β 小: $\exp(r/\beta)$ 更尖锐, 主导偏好更容易被放大。
- β 大: reward 差异被压平, 模型更受 reference 约束。

当 $\beta < 1$ 时, 如果 $p_{\text{reward}}(y) > 0.5$, 主导回答会被进一步放大; 极端时也可能导致 preference collapse (附录 A.3)。

过渡：为什么需要 Preference Matching

标准 KL-RLHF 的问题：

$$p_{\text{rlhf}} \propto p_{\text{ref}} \cdot p_{\text{reward}}.$$

但我们真正希望：

$$\frac{\pi(y_1|x)}{\pi(y_1|x) + \pi(y_2|x)} = P(y_1 \succ y_2 | x, y_1, y_2).$$

这就是后续提出的 **Preference Matching**

模型输出概率应匹配 reward model 所表达的人类偏好分布，而不是被 reference model 的先验偏差重新塑形。

3. From KL-RLHF to PM Regularization (从 KL-RLHF 到偏好匹配正则)

- 3.1 Problems of KL-RLHF (KL-RLHF 的问题)
- 3.2 Preference Matching Regularization (偏好匹配正则)

3.1 从 PM 定义引出 ODE

考虑更一般的正则化形式:

$$\max_{\pi} \sum_{i=1}^k \pi_i (r_i + R(\pi_i)), \quad \sum_i \pi_i = 1.$$

若最优解满足 PL 模型下的 PM policy:

$$\pi_i^{\star} = \frac{\exp(r_i)}{\sum_j \exp(r_j)},$$

一阶条件会推出:

$$R(\pi_i^{\star}) + \pi_i^{\star} R'(\pi_i^{\star}) = -\log \pi_i^{\star} + c.$$

把 $\pi_i^{\star}$ 视为变量并求导, 得到 PM differential equation:

$$\pi R''(\pi) + 2R'(\pi) + \frac{1}{\pi} = 0.$$

3.2 ODE 的解: PM Regularization

PM differential equation:

$$\pi R''(\pi) + 2R'(\pi) + \frac{1}{\pi} = 0$$

的通解为:

$$R(\pi) = -\log \pi + C_{1,x} + \frac{C_{2,x}}{\pi}.$$

其中 $\frac{C_{2,x}}{\pi}$ 在期望中不影响优化, 因此核心正则项是:

$$R(\pi) = -\log \pi(y|x).$$

PM-RLHF 的理想目标可以写为:

$$\max_{\phi} \mathbb{E}_{y \sim \pi_{\phi}(\cdot|x)} [r(x, y) - \log \pi_{\phi}(y|x)].$$

3.3 Entropy 的直觉：奖励异质性

对生成分布取期望后：

$$\mathbb{E}_{y \sim \pi(\cdot|x)} [-\log \pi(y|x)]$$

正是 Shannon entropy。

Reward 项

鼓励模型选择更受欢迎、更高质量的回答。

Entropy 项

防止模型把全部概率压到单一回答上，保留合理多样性。

直觉： PM regularization 不是随意增加随机性，而是用熵正则奖励偏好异质性，使模型输出概率更接近人类偏好比例。

3.4 Entropy 的数值例子

假设同一个 prompt 下只有两个合理回答 y_1, y_2 。Shannon entropy 为：

$$H(\pi) = - \sum_i \pi_i \log \pi_i.$$

模型输出分布 $\pi(y_1, y_2)$	含义	$H(\pi)$
(1.0, 0.0)	完全坍缩	0
(0.9, 0.1)	高度偏向 y_1	0.325
(0.6, 0.4)	保留少数偏好	0.673
(0.5, 0.5)	两者几乎一样常见	0.693

如何理解这些数字？

熵不是在奖励“越随机越好”，而是在惩罚过度集中。若真实偏好接近 60/40，输出 (0.9, 0.1) 虽然更确定，但会明显压缩 y_2 代表的少数偏好。

4. Conditional PM RLHF (条件偏好匹配 RLHF)

- 4.1 Practical Difficulties (实践困难)
- 4.2 Conditional PM RLHF (条件偏好匹配)

4.1 直接使用 PM-RLHF 的实践困难

理论上的 PM-RLHF 会鼓励多样性，但自然语言生成有一个额外问题：文本空间极大，绝大部分 token 序列并不是自然回答。

- Reward model 通常只在自然文本附近可靠。
- 如果在整个响应空间上做 PM，模型可能给不自然文本过高概率。
- 这不是理论目标错了，而是语言生成空间太大、reward model 泛化区域有限。

论文的处理

将 PM-RLHF 改造成 Conditional PM-RLHF：只在自然、合理的回答集合中做 preference matching。

4.2 直接 PM-RLHF 的失败案例

Prompt	PM-RLHF 生成结果
What was the name of the movie that won the Academy Award for Best Picture in 1955?	The movie that
Why do birds migrate south for the winter?	The birds migrate south for the winter because the climate ... is the most suitable ... The climate ... is the most suitable ...
Human: thank thank thank ...	thank thank thank thank thank ...

解读

直接 PM-RLHF 的熵正则确实鼓励了多样性，但没有限制生成空间时，模型可能生成截断、重复或无意义文本。

4.3 Conditional PM: 只在自然回答中匹配偏好

论文把响应空间分成两部分:

$$\mathcal{Y} = M(x) \cup (\mathcal{Y} \setminus M(x)).$$

- $M(x)$: 对 prompt x 来说自然、合理、reward model 较可靠的回答集合。
- $\mathcal{Y} \setminus M(x)$: 不自然、无意义或 reward model 不可靠的区域。

实际实现中, 作者用 reference model 的概率来定义自然集合:

$$M(x) = \{y : \pi_{\text{ref}}(y|x) \geq \alpha\}.$$

注意: 这里 reference model 不是用来决定偏好, 而是用来判断“哪些文本像自然语言”。

4.4 最终采用的优化目标

论文实验中使用的 Conditional PM-RLHF:

$$\max_{\phi} \mathbb{E}_{y \sim \pi_{\phi}(\cdot|x)} \left[r(x, y) - \log \pi_{\phi}(y|x) \mathbf{1}\{\pi_{\text{ref}}(y|x) \geq \alpha\} - \log \frac{\pi_{\phi}(y|x)}{\pi_{\text{ref}}(y|x)} \mathbf{1}\{\pi_{\text{ref}}(y|x) < \alpha\} \right].$$

- α 是唯一显式调节参数。
- $\pi_{\text{ref}}(y|x) \geq \alpha$: 认为回答足够自然, 使用 PM entropy regularizer。
- $\pi_{\text{ref}}(y|x) < \alpha$: 认为回答可疑, 用 KL-like penalty 拉回 reference model。

也就是说, Conditional PM-RLHF 在自然语言区域内奖励异质性, 在不自然区域内保持保守。

5. Evaluation and Experiments (评价指标与实验结果)

- 5.1 Evaluation Metrics (评价指标)
- 5.2 Empirical Results (实验结果)

5.1 实验评价指标

- PM Divergence: 模型偏好分布与 reward model 偏好分布的 KL 距离, 越低越好。
- Average Generation Length: 平均生成长度。
- Perplexity: 语言模型困惑度, 衡量生成文本的自然性与可预测性, 越低越好。
- Entropy: 输出多样性。
- KL Divergence: 训练后模型与 reference model 的距离。

5.2 Table 1: 实验中的 β

在实验中，作者将 reward 写作 $r(x, y) = r_\theta(x, y)/\beta$ 。因此， β 可以理解为 reward 的缩放系数。

- 小 β 会放大 reward 差异，使偏好分布更尖锐，模型更偏向高 reward 响应。
- 大 β 会压缩 reward 差异，使偏好分布更平滑。
- $\beta = 1$ 与论文理论设定最一致，因此表中 $\beta = 1$ 的结果尤其值得关注。

另一个关键参数是 α ：它控制 conditional PM 中“自然回答集合”的宽窄。

5.3 Table 1

β	方法	PM Div. ↓	Length	PPL ↓	Entropy	KL
0.1	$\alpha = 0.1$	1.33	256	6.17	0.90	0.11
	$\alpha = 0.3$	1.37	246	5.74	0.82	0.08
	$\alpha = 0.5$	1.40	207	5.55	0.88	0.06
	KL-RLHF	1.53	131	5.48	0.92	0.05
0.5	$\alpha = 0.1$	1.58	256	7.17	0.78	0.15
	$\alpha = 0.3$	1.46	253	5.57	0.81	0.07
	$\alpha = 0.5$	1.57	221	5.13	0.95	0.03
	KL-RLHF	1.98	115	4.91	1.01	0.01
1.0	$\alpha = 0.1$	1.71	256	10.73	0.56	0.22
	$\alpha = 0.3$	1.57	254	5.64	0.79	0.07
	$\alpha = 0.5$	1.62	227	5.08	0.96	0.03
	KL-RLHF	2.23	108	4.82	1.05	0.01

Conditional PM-RLHF 在所有 β 设置下都降低 PM Divergence; 当 $\beta = 1.0, \alpha = 0.3$ 时, 从 2.23 降至 1.57。

5.4 Table 2

模型	方法	PM Div. ↓	Length	PPL ↓	Entropy	KL
Llama-2-7B	PM-RLHF	1.73	36	4.34	0.96	0.00
	KL-RLHF	1.96	44	4.34	0.81	0.00
Llama-3.2-1B	$\alpha = 0.1$	1.75	33	5.80	1.18	0.00
	$\alpha = 0.3$	1.76	32	5.78	1.19	0.00
	KL-RLHF	1.75	33	5.77	1.20	0.00
Llama-3.2-3B	$\alpha = 0.1$	1.37	36	4.84	1.28	0.00
	$\alpha = 0.3$	1.37	40	4.84	1.25	0.00
	KL-RLHF	1.50	36	4.87	1.27	0.00

PM-RLHF 在 Llama-2-7B 和 Llama-3.2-3B 上降低 PM Divergence; Llama-3.2-1B 几乎没有改善, 说明模型规模可能影响偏好保留能力。

6. Discussion (余论)

- 6.1 LLMs in Research (LLM 参与研究)
- 6.2 Cautionary Takeaways (使用提醒)

6.1 LLM 正在直接参与各学科研究

LLM 不再只是被研究对象，也越来越多地成为研究工具：

- Homo silicus: Horton et al. (2023) 将 LLM 作为模拟经济主体，用于分析经济行为和实验决策。
- Synthetic survey data: Argyle et al. (2023) 使用 LLM 构造 “silicon samples”，模拟不同人口群体的问卷回答。
- Simulated participants: Aher et al. (2023) 用 LLM 模拟人类被试，复现经典心理学与行为经济学实验。
- Agent-based research: 多智能体 LLM 被用于模拟市场互动、组织行为、舆论传播与社会网络。

共同前提： LLM 的输出可以在某种意义上代理人类意见、行为或偏好。

6.2 Why this paper matters?

- 如果 LLM 倾向于输出主流意见，研究者可能会把“模型偏好”误读为“人群偏好”。
- 如果少数派偏好被压缩，synthetic survey data 会低估社会异质性。
- 如果模型行为来自训练目标和 reference model 偏差，模拟经济主体未必代表真实经济主体。

与 preference collapse 的连接

Preference collapse 提醒我们：LLM 输出的意见分布可能是训练过程塑造出来的，而不是现实人群偏好分布的自然反映。

6.3 使用 LLM 做研究时应保持警惕

- 不只看平均回答，也要看回答分布、尾部偏好和群体差异。
- 对不同 persona、语言、prompt 表述和采样参数做稳健性检查。
- 尽量用真实调查、实验或市场数据校准 LLM 输出。
- 把 LLM 看作可辅助研究的工具，而不是未经验证的真实人群替代品。

最后的 Takeaway

在我们真正探索清楚 LLM 这个“黑箱”之前，不应理所当然地将其视为万能工具；尤其在涉及人类偏好和社会异质性时，更需要持续检查模型是否系统性抹平 minority preference。

敬请各位老师、同学批评指正！

谢谢大家！

On the Algorithmic Bias of Aligning Large Language Models with RLHF: Preference
Collapse and Matching Regularization