

计量经济学（荣誉课） 课程笔记

整理者：子非鱼

Contents

I Part I	5
1 Basics	5
2 简单二元回归	5
2.1 Basics	5
2.2 OLS 代数特性	6
2.3 拟合优度	6
2.4 OLS 的若干假定	6
2.5 无偏性	7
2.6 补充: Bootstrap 法	8
2.7 方差	10
3 多元回归	11
3.1 Basics	11
3.2 “Partialling Out” interpretation	11
3.3 矩阵描述的多元回归模型	12
3.4 补充: FWL 定理	13
3.5 遗漏变量偏误	14
3.6 方差	16
3.7 OLS 的优良性: Gauss-Markov 定理	18
3.8 拟合优度	18
4 推断与假设检验	19
4.1 Basics	19
4.2 T-test	19
4.3 F-test	20
4.4 Understanding Stata Output	20
5 大样本特性——Asymptotics	22
5.1 Why we care about asymptotics?	22
5.2 Consistency——一致性	22
6 其他	23
6.1 Data Scaling	23
6.2 Beta Coefficients/Standardization	23
6.3 Models with Quadratics	23

6.4	Models with Interaction Terms	24
7	异方差	24
7.1	影响	24
7.2	方差	24
7.3	稳健标准误	24
7.4	异方差的检验	24
7.5	加权最小二乘法	25
II	Part II	27
8	模型规范与数据	27
8.1	代理变量 (Proxy variables)	27
8.2	测量误差	27
8.2.1	因变量情形	27
8.2.2	自变量情形	28
8.3	数据缺失	28
8.3.1	MCAR	28
8.3.2	非随机样本	29
8.4	离群值	29
9	时间序列分析	30
9.1	基础概念	30
9.2	经典模型	30
9.2.1	静态模型 (Static Model)	30
9.2.2	分布滞后模型 (Finite Distributed Lag Model)	30
9.2.3	事件研究模型 (Event Study Model)	30
9.3	OLS 性质	31
9.3.1	无偏性	31
9.3.2	方差	31
9.3.3	正态性	31
9.4	趋势与季节性	31
9.5	自回归模型	32
9.5.1	Granger 检验	32
9.5.2	自回归模型——序列误差相关的情形	32
10	定性信息建模	33
10.1	单虚拟变量	33

10.2 虚拟变量间交互	34
10.2.1 DID (difference in differences)	34
10.2.2 其他模型	34
10.2.3 邹检验 (Chow-test)	35
10.3 注意事项	35
10.4 概率模型	35
10.4.1 线性概率模型 (LPM, linear probability model)	35
10.4.2 Logit 和 Probit 模型	36
10.5 其他	36
10.5.1 经济显著性与统计显著性	36
10.5.2 不显著的变量?	37
11 面板数据	37
11.1 面板数据基础	37
11.2 模型	37
11.2.1 固定效应模型	37
11.2.2 随机效应模型	39
12 工具变量	39
12.1 引入	39
12.2 回归模型	40
12.3 统计性质	40
12.4 工具变量的优良	41
12.5 多元回归中的工具变量	41
12.6 矩阵版本的 IV	41
12.6.1 基本模型与假设	41
12.6.2 工具变量构造	42
12.6.3 估计量推导	42

Part I

Part I

1 Basics

数据：

- 截面数据 (cross-sectional data)

在给定的时点收集的包含个体信息的样本

- 时间序列数据 (time-series data)
- 面板数据 (panel data)

又称跟踪数据、追踪数据，是对截面的每一个个体的时间序列数据的集合。注意，需是对同一个个体的追踪，否则称为重复截面

时序数据与面板数据的核心区别：面板数据通过截面维度引入**个体异质性分析**，时间序列仅关注**时间维度**动态。

2 简单二元回归

2.1 Basics

基本模型：

$$y = \beta_0 + \beta_1 x + u$$

其中 u 称为误差项或扰动项，代表除了 x 之外可以影响 y 的因素
一个基本的假定是：

$$\mathbb{E}(u|x) = 0$$

即**条件期望零值假定**

这可进一步导出

$$\mathbb{E}(xu) = 0$$

利用矩估计，我们可以得到系数的估计量

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

另一个导出估计量的方法则是标准的 OLS 法：最小化残差平方和

$$\min \sum_{i=1}^n \hat{u}_i^2$$

其中残差 $\hat{u}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$

注：误差与残差的区别

误差是模型中事先假定的，是一个理论值，无法被观测到

残差则被定义为真实值与预测值之间的差，是一个根据样本数据的计算值

2.2 OLS 代数特性

- 残差之和为零

$$\sum_{i=1}^n \hat{u}_i = 0$$

- OLS 回归线经过样本均值

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

- 解释变量与 OLS 残差的样本协方差为零

$$\sum_{i=1}^n x_i \hat{u}_i = 0$$

此即 OLS 方法得到的第二个一阶条件

- 预测值与残差在样本中是不相关的

$$\frac{1}{n-1} \sum_{i=1}^n (\hat{y}_i - \bar{y})(\hat{u}_i - \bar{\hat{u}}) = 0$$

由 1、3 条代数特性得到

2.3 拟合优度

定义

$$\begin{aligned} SST &= \sum_{i=1}^n (y_i - \bar{y})^2 \\ SSE &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \\ SSR &= \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \end{aligned}$$

对于 OLS 模型，总成立

$$SST = SSE + SSR$$

利用

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

衡量拟合优度， R^2 表示 y 的样本变动中被解释了的部分占比

2.4 OLS 的若干假定

- 关于参数的线性

也即模型的假定

$$y = \beta_0 + \beta_1 x + u$$

- 随机抽样

具体而言，其数学含义是样本观测 (x_i, y_i) 独立同分布

- 条件期望零值假定
- 不完全共线性

样本中的 x_i 不全相等。对于多元线性回归模型，则可认为是设计矩阵 X 满秩

2.5 无偏性

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \beta_1 + \frac{Cov(X, u)}{Var X}\end{aligned}$$

由条件期望零值假定 $\mathbb{E}(u_i|x_i) = 0$ 易得

$$\mathbb{E}(\hat{\beta}_1|x) = \beta_1$$

进而

$$\begin{aligned}\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \\ &= \beta_0 + (\beta_1 - \hat{\beta}_1) \bar{x} + \bar{u} \Rightarrow \mathbb{E}(\hat{\beta}_0|x) = \beta_0\end{aligned}$$

注意，无偏性的推导强烈依赖于条件期望零值假定，因此当该假定失效（例如遗漏变量偏误等发生）时，估计量可能是有偏的

一个例子是：

在案例 “**Example 2.12: Unbiasedness fails when any of the four assumptions fails**” 中，回归模型估计结果为：

$$\widehat{\text{math10}} = 32.14 - 0.319 \text{ Inchprg}$$

其中，`math10` 表示 10 年级学生的数学成绩，`Inchprg` 是学校参与免费午餐项目的学生比例。**反常现象**在于：回归结果显示，参与免费午餐项目的学生比例（`Inchprg`）**每增加 1%**，数学成绩（`math10`）**反而下降约 0.319 分**，这与直觉预期（免费午餐可能改善学生营养和学习条件，从而提高成绩）相矛盾。

以下从 **OLS 无偏性假设失效**的角度解释这一反常现象：

1. 核心问题：零条件均值假设被违反

OLS 的无偏性依赖于 **零条件均值假设** ($\mathbb{E}(u_i|x_i) = 0$)，即误差项 u_i 与解释变量 x_i (`Inchprg`) 不相关。

在本例中，**遗漏变量偏误** (Omitted Variable Bias) 极可能是导致反常结果的原因：

- **潜在遗漏变量：**

- **家庭经济状况:** Inchprg (免费午餐参与率) 高的学校通常对应低收入家庭学生比例较高, 而家庭收入低可能直接影响学生成绩 (如缺乏学习资源、父母教育水平低等)。
- **学校资源差异:** 低收入社区学校可能资金不足, 师生比高、教学设施差, 进一步拉低成绩。
- **偏误方向:** 若遗漏变量 (如家庭收入) 与 Inchprg 负相关 (免费午餐参与率高对应家庭收入低), 且与 math10 正相关 (家庭收入高提升成绩), 则 Inchprg 的系数会被 **向下偏误** (低估负效应或高估正效应)。本例中, 模型遗漏了家庭收入等变量, 导致 Inchprg 的系数被错误估计为负值。

2. 其他可能违反的假设

除零条件均值假设外, 以下问题也可能导致反常结果: - **内生性 (Endogeneity):**

- **反向因果:** 数学成绩差的学校可能更倾向于扩大免费午餐项目覆盖范围 (政策干预), 导致 Inchprg 与误差项相关。
- **测量误差:** 若 Inchprg 的测量存在误差 (如实际参与率与报告值不符), 会导致估计偏误。
- **模型设定错误:**
 - 非线性关系被忽略 (如成绩与贫困率可能存在 U 型关系)。
 - 未控制学校特征变量 (如师生比、教师学历、课外辅导资源)。

本例中的反常现象 (免费午餐项目与数学成绩负相关) **并非因果关系**, 而是由 **遗漏变量偏误** 或 **内生性问题** 导致的无偏性失效。它警示我们在实证分析中必须严格检验 OLS 假设, 避免从有偏估计中得出错误结论。尤其是在政策评估中, 需结合理论逻辑与严谨方法 (如因果推断技术) 进行验证。

2.6 补充: Bootstrap 法

Bootstrap 方法简介

Bootstrap (自助法) 是一种基于计算机的 **重抽样 (Resampling)** 统计技术, 由 Bradley Efron 于 1979 年提出, 用于估计统计量的抽样分布、标准误、置信区间等, 尤其适用于 **小样本或分布未知** 的复杂问题。其核心思想是通过对原始样本进行重复抽样, 模拟 “从总体中多次抽样” 的过程, 从而逼近统计量的真实分布。

1. 核心思想

- **核心假设:** 原始样本是总体分布的近似, 通过有放回地重复抽样, 生成大量 “伪样本” (Bootstrap 样本), 从而模拟统计量的变异性。
- **核心目标:** 无需依赖传统理论 (如中心极限定理), 直接通过数据本身推断统计量的性质。

2. 基本步骤

以估计统计量 θ (如均值、回归系数) 的置信区间为例: 1. **从原始样本中重抽样:** 从原始样本 $\{x_1, x_2, \dots, x_n\}$ 中 **有放回地随机抽取** n 个观测值, 形成一个 Bootstrap 样本 $D^* = \{x_1^*, x_2^*, \dots, x_n^*\}$ 。

- 每个观测值被抽中的概率为 $1/n$ ，允许重复（如某观测值可能被抽中多次，而其他观测值未被抽中）。
- 2. **计算 Bootstrap 统计量**: 对每个 Bootstrap 样本 D^* ，计算目标统计量的估计值 $\hat{\theta}^*$ （如样本均值、中位数、回归系数等）。
- 3. **重复多次**:
重复步骤 1-2 共 B 次（通常 $B \geq 1000$ ），得到 Bootstrap 统计量的集合 $\{\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*\}$ 。
- 4. **推断统计量分布**:
 - **标准误估计**: 计算 Bootstrap 统计量的标准差:

$$SE_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2}$$

其中 $\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*$ 。

- **置信区间**:
 - **百分位数法**: 取 Bootstrap 统计量的 $\alpha/2$ 和 $1 - \alpha/2$ 分位数（如 95% 置信区间取 2.5% 和 97.5% 分位数）。
 - **偏差校正法 (BCa)**: 调整百分位数以修正偏差。

3. 主要类型

1. **非参数 Bootstrap**:
 - 直接对原始样本进行重抽样，**不假设总体分布形式**，最常用。
2. **参数 Bootstrap**:
 - 假设总体服从某参数分布（如正态分布），先估计分布参数，再从该分布中生成新样本。

4. 应用场景

1. **估计标准误与置信区间**:
 - 传统方法难以计算时（如中位数、相关系数、分位数回归系数）。
 - 示例：用 Bootstrap 估计回归系数的标准误（替代传统 OLS 公式）。
2. **检验假设**:
 - 生成统计量的经验分布，计算 p 值（如置换检验）。
3. **模型评估**:
 - 评估模型稳定性（如交叉验证的补充）。
4. **小样本问题**:

- 当样本量过小，传统渐近理论失效时。

5. 优缺点

- **优点：**
 - 不依赖总体分布假设，适用于复杂统计量。
 - 直观易实现（依赖计算能力而非数学推导）。
 - 可处理传统方法无法解决的问题（如中位数的置信区间）。
- **缺点：**
 - **计算成本高：**需大量重复抽样，对大规模数据不友好。
 - **对原始样本敏感：**若原始样本偏离总体，Bootstrap 结果可能误导。
 - **某些场景不适用：**如极端值主导的统计量（如最大值）。

总结：Bootstrap 通过重抽样模拟统计量的变异性，是一种灵活强大的非参数推断工具，广泛应用于实证研究，尤其在传统理论受限时提供了一种数据驱动解决方案。

2.7 方差

为推导估计量的方差，补充假定

- $Var(u|x) = \sigma^2$

可以得到

$$Var(\hat{\beta}_1|x) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}$$

$$Var(\hat{\beta}_0|x) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \frac{\sum_{i=1}^n x_i^2}{n}$$

由于 σ 是未知的，我们利用以下无偏估计量进行估计

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n-2}$$

记号：

- 标准差 standard deviation $sd(\hat{\beta}_1) = \frac{\sigma}{\sqrt{SST_x}}$
- 标准误 standard error $se(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{SST_x}} = \sqrt{\frac{\sum_{i=1}^n \hat{u}_i^2}{(n-2)SST_x}}$

3 多元回归

3.1 Basics

基本模型为：

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u$$

OLS 得到的 $k+1$ 个一阶条件为

$$\begin{aligned} \sum_{i=1}^n \hat{u}_i &= 0 \\ \sum_{i=1}^n x_{il} \hat{u}_i &= 0, l = 1, \dots, k \\ &\Rightarrow \\ \sum_{i=1}^n \hat{y}_i \hat{u}_i &= 0 \end{aligned}$$

注： x_{il} 的第一个角标表示数据组数，第二个角标表示第 l 个变量（与设计矩阵中的角标相对应）

3.2 “Partialling Out” interpretation

我们可以通过多步回归的方法得到 OLS 估计量

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n \hat{r}_{i1} y_i}{\sum_{i=1}^n \hat{r}_{i1}^2}$$

其中 $\hat{r}_{i1}$ 是 x_1 对 $x_2, \dots, x_k$ 回归得到的残差

因此，上式中的估计量 $\hat{\beta}_1$ 衡量的是在排除 $x_2, \dots, x_k$ 的影响后， x_1 对 y 的独立效应。

证明：

Use the OLS first order condition, show that for $j = 0, 1, \dots, k$, we can express the OLS estimators $\hat{\beta}_j$ as

$$\hat{\beta}_j = \left(\sum_{i=1}^n \hat{r}_{ij} y_i \right) / \left(\sum_{i=1}^n \hat{r}_{ij}^2 \right) = \left(\sum_{i=1}^n \hat{r}_{ij} \tilde{r}_i \right) / \left(\sum_{i=1}^n \hat{r}_{ij}^2 \right)$$

where $\hat{r}_{ij}$ are the OLS residuals from a multiple regression of x_j on all other independent variables (and including an intercept), and $\tilde{r}_i$ are the OLS residuals from a multiple regression of y on all other independent variables (and including an intercept).

Proof: The OLS first order conditions are

$$\begin{aligned}
\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik}) &= 0 \\
\sum_{i=1}^n x_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik}) &= 0 \\
&\vdots \\
\sum_{i=1}^n x_{ik} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik}) &= 0
\end{aligned}$$

Take $\hat{\beta}_1$ as an example. Notice that $x_{i1} = \hat{x}_{i1} + \hat{r}_{i1}$, $i = 1, \dots, n$, where $\hat{x}_{i1}$ is the fitted value of the regression of x_1 on other regressors. Then the OLS first order condition with x_1 can be expressed as

$$\sum_{i=1}^n (\hat{x}_{i1} + \hat{r}_{i1}) (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik}) = 0$$

Notice that $\hat{x}_{i1}$ is a linear combination of $x_{i2}, \dots, x_{ik}$ and constant. Using other FOCs, we have $\sum_{i=1}^n \hat{x}_{i1} \hat{u}_i = 0$. Then the OLS first order condition with x_1 can be expressed as

$$\sum_{i=1}^n \hat{r}_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik}) = 0$$

Then notice that $\hat{r}_{i1}$ is the residual of the regression of x_1 on other regressors, thus $\sum_{i=1}^n x_{ij} \hat{r}_{i1} = 0$, $j = 2, \dots, k$ and $\sum_{i=1}^n \hat{r}_{i1} = 0$. Then the OLS first order condition with x_1 can be expressed as

$$\sum_{i=1}^n \hat{r}_{i1} (y_i - \hat{\beta}_1 x_{i1}) = 0$$

Finally, using $\sum_{i=1}^n \hat{x}_{i1} \hat{r}_{i1} = 0$, we have $\sum_{i=1}^n \hat{r}_{i1} (y_i - \hat{\beta}_1 \hat{r}_{i1}) = 0$, thus we complete the first part of the proof.

For the second part of the proof, notice that $\tilde{r}_i$ is the residual of the regression of y on other regressors, thus $y_i - \tilde{r}_i$ is a linear combination of $x_{i2}, \dots, x_{ik}$ and constant, then $\sum_{i=1}^n \hat{r}_{i1} (y_i - \tilde{r}_i) = 0$, and we can further express the FOC as $\sum_{i=1}^n \hat{r}_{i1} (\tilde{r}_i - \hat{\beta}_1 \hat{r}_{i1}) = 0$, thus we complete the second part of the proof.

更进一步我们可以得到

$$\hat{\beta}_j = \beta_j + \frac{\sum_{i=1}^n \hat{r}_{ij} u_i}{\sum_{i=1}^n \hat{r}_{ij}^2}$$

3.3 矩阵描述的多元回归模型

模型变为:

$$Y = X\beta + u$$

由 OLS 易得

$$\hat{\beta} = (X'X)^{-1}X'Y$$

定义投影矩阵及其正交补

$$P = X(X'X)^{-1}X'$$

$$M = I - P$$

则

$$\hat{Y} = PY$$

$$\hat{u} = MY$$

以及协方差矩阵

$$\text{Var}(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$$

3.4 补充: FWL 定理

有时候, 我们并不关心 OLS 模型里面所有的系数, 例如, 面板固定效应里面固定效应对应的系数. 我们当然可以暴力求解出所有回归系数, 然后选取我们感兴趣的, 但这对于时间和算力都无疑是一种浪费. 幸运的是, least square 目标函数的优良性质允许我们对系数进行分步优化, 具体而言, 假设 $X = [X_1, X_2]$, $Y = X_1\beta_1 + X_2\beta_2 + e$. 如果我们仅仅对 $\hat{\beta}_1$ 感兴趣, 我们有

$$(\hat{\beta}_1, \hat{\beta}_2) = \min_{\beta_1, \beta_2} \text{SSE}(\beta_1, \beta_2) = \min_{\beta_1} \left(\min_{\beta_2} \text{SSE}(\beta_1, \beta_2) \right)$$

容易知道

$$\hat{\beta}_2 = (X_2^\top X_2)^{-1} X_2^\top (Y - X_1\beta_1)$$

$$Y - X_1\beta_1 - X_2\hat{\beta}_2 = M_2(Y - X_1\beta_1)$$

$$\min_{\beta_2} \text{SSE}(\beta_1, \beta_2) = (M_2(Y - X_1\beta_1))^\top (M_2(Y - X_1\beta_1))$$

其中 $M_2 = I_n - X_2(X_2^\top X_2)^{-1}X_2^\top$. 我们可以把 M_2Y 和 M_2X_1 看成新的因变量和自变量, 从而有

$$\hat{\beta}_1 = ((M_2X_1)^\top (M_2X_1))^{-1} ((M_2X_1)^\top (M_2Y)) = (X_1^\top M_2X_1)^{-1} (X_1^\top M_2Y)$$

类似即有

$$\hat{\beta}_2 = (X_2^\top M_1X_2)^{-1} (X_2^\top M_1Y)$$

这就是著名的 FWL 定理. 利用上述公式, 我们就可以在线性模型中得到我们关心的部分系数的显式解, 这种想法和操作技巧可以帮助我们很好地理解散装版本中的 partial out effect, 在后续的面板回归模型的学习中也非常常见.

FWL 定理也给之前的 Partialling out interpretation 给出了矩阵形式的直观证明:

考虑标准的多元回归模型:

$$Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + u$$

以下是两种求 $\hat{\beta}_1$ 的方法

方法 1：一步到位法（标准多元回归）

直接建立多元回归：

$$Y \sim X_1 + X_2 \Rightarrow \text{得到 } \hat{\beta}_1$$

这是我们最熟悉的方法，其内在含义由 FWL 定理揭示

方法 2：三步“净化”法（FWL 分解）

要获得完全相同的 $\hat{\beta}_1$ ，可进行以下三步操作：

第 1 步：净化核心变量 X_1

将 X_1 对控制变量 X_2 回归并提取残差：

$$X_1 \sim X_2 \Rightarrow \text{残差 } \tilde{X}_1$$

直观而言， $\tilde{X}_1$ 是 X_1 中剔除 X_2 所有线性影响后的“纯粹”部分，即 X_1 中不可被 X_2 解释的信息

第 2 步：净化因变量 Y

将 Y 对控制变量回归 X_2 并提取残差：

$$Y \sim X_2 \Rightarrow \text{残差 } \tilde{Y}$$

同样的， $\tilde{Y}$ 是 Y 中剔除 X_2 所有线性影响后的“纯粹”部分

第 3 步：最终回归

将净化后的变量进行一元回归：

$$\tilde{Y} \sim \tilde{X}_1 \Rightarrow \text{得到 } \hat{\gamma}_1$$

FWL 定理保证了：

三大步骤得到的系数与原多元回归系数恒等：

$$\hat{\gamma}_1 = \hat{\beta}_1$$

这意味着：通过控制变量“净化”后的残差回归，可获得完全等同于多元回归的纯净估计

3.5 遗漏变量偏误

在多元回归中，如果我们没有把应当纳入的自变量纳入回归，一般而言会导致遗漏变量偏误。具体而言，令 $\hat{\beta}_j, j = 0, 1, \dots, k$ 为使用了所有自变量的回归对应的 OLS 估计量，令 $\tilde{\beta}_j, j = 0, 1, \dots, k-1$ 为遗漏了 x_k 的回归对应的 OLS 估计量，令 $\tilde{\delta}_j, j = 1, \dots, k-1$ 为 x_{ik} 对 $x_{i1}, x_{i2}, \dots, x_{i,k-1}, i = 1, \dots, n$ 进行的辅助回归中 x_j 对应的斜率系数，我们有

$$\tilde{\beta}_j = \hat{\beta}_j + \hat{\beta}_k \tilde{\delta}_j$$

证明：我们以 $\tilde{\beta}_1$ 为例进行推导。定义 $\tilde{r}_{i1}$ 是 x_1 对 $x_2, \dots, x_{k-1}$ 和截距项回归中 x_{i1} 对应的残差，那么

$$\tilde{\beta}_1 = \frac{\sum_{i=1}^n \tilde{r}_{i1} y_i}{\sum_{i=1}^n \tilde{r}_{i1}^2}$$

考虑包含所有自变量的回归，我们可以把 y_i 写成

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ik} + \hat{u}_i, i = 1, \dots, n$$

利用 $\sum_{i=1}^n \tilde{r}_{i1} = 0$ 和 $\sum_{i=1}^n \tilde{r}_{i1} x_{ij} = 0, j = 2, \dots, k-1$ ，以及 $\sum_{i=1}^n \tilde{r}_{i1} x_{i1} = \sum_{i=1}^n \tilde{r}_{i1}^2$ ，有

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_k \frac{\sum_{i=1}^n \tilde{r}_{i1} x_{ik}}{\sum_{i=1}^n \tilde{r}_{i1}^2}$$

注意到 $\sum_{i=1}^n \tilde{r}_{i1} x_{ik} / \sum_{i=1}^n \tilde{r}_{i1}^2$ 恰为 x_{ik} 对 $x_{i1}, x_{i2}, \dots, x_{i,k-1}, i = 1, \dots, n$ 进行的辅助回归中 x_1 对应的斜率系数 $\tilde{\delta}_1$ ，从而原命题证毕。

关键公式的直观拆解

原公式：

$$\tilde{\beta}_j = \hat{\beta}_j + \hat{\beta}_k \tilde{\delta}_j$$

- $\hat{\beta}_j$ ：控制所有变量后， x_j 对 y 的真实效应。
- $\hat{\beta}_k \tilde{\delta}_j$ ：遗漏 x_k 导致的偏误，等于 x_k 的效应乘以其与 x_j 的关联。

记忆逻辑： - 如果 x_k 与 x_j 无关 ($\tilde{\delta}_j = 0$)，遗漏变量不会导致偏误。

- 如果 x_k 对 y 无影响 ($\hat{\beta}_k = 0$)，遗漏变量也不会导致偏误。

快速判断偏误方向

通过以下两步判断偏误方向：

1. 确定 $\hat{\beta}_k$ 的符号：

- 若 x_k 对 y 有正向影响， $\hat{\beta}_k > 0$ ；反之则 $\hat{\beta}_k < 0$ 。

2. 确定 $\tilde{\delta}_j$ 的符号：

- 若 x_k 与 x_j 正相关， $\tilde{\delta}_j > 0$ ；反之则 $\tilde{\delta}_j < 0$ 。

3. 综合判断：

- 若 $\hat{\beta}_k$ 与 $\tilde{\delta}_j$ 同号，则 $\tilde{\beta}_j$ 的偏误为 **正向**（高估或低估同方向）。

- 若 $\hat{\beta}_k$ 与 $\tilde{\delta}_j$ 异号，则偏误为 **负向**（效应被反向扭曲）。

示例：

- 若 $\hat{\beta}_k > 0$ (x_k 对 y 正向影响) 且 $\tilde{\delta}_j > 0$ (x_k 与 x_j 正相关)，则：

$$\tilde{\beta}_j = \hat{\beta}_j + (\text{正数} \times \text{正数}) = \hat{\beta}_j + \text{正偏误}$$

x_j 的效应会被 **高估**。

3.6 方差

对于多元回归的 OLS 估计,在给定同方差的假定后,我们可以由 $\hat{\beta}_j = \beta_j + (\sum_{i=1}^n \hat{r}_{ij}u_i) / \left(\sum_{i=1}^n \hat{r}_{ij}^2\right)$ 直接得到

$$Var(\hat{\beta}_j|X) = \frac{\sigma^2}{SST_j(1 - R_j^2)}, j = 1, \dots, k$$

其中

$$SST_j = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$$

其中 R_j^2 是 x_j 对其他自变量进行辅助回归得到的决定系数 OLS 估计的方差越大,说明其估计值越不稳定

σ 来源于模型本身

SST_j 表示的是解释变量 x_j 的分散程度

$1 - R_j^2$ 则衡量了 x_j 与其他解释变量的多重共线性程度,值越小共线性越强

注:关于不完全共线性

多元回归模型中完全共线性的影响

在多元回归模型中, **不完全共线性假设 (No Perfect Multicollinearity)** 是 OLS 估计的核心前提之一。若这一假设不成立 (即存在完全共线性), 模型将面临以下问题:

1. 无法估计唯一参数

- **数学本质:** 完全共线性意味着至少有一个自变量可以表示为其他自变量的 **严格线性组合**, 导致设计矩阵 X **列不满秩**, 矩阵 $X'X$ 不可逆。
 - 例如: 若模型中同时包含 x_1 和 $x_2 = 2x_1 + 3$, 则 x_1 与 x_2 完全共线。
- **后果:**
 - OLS 估计量 $\hat{\beta} = (X'X)^{-1}X'y$ **无法计算**, 统计软件会报错 (如 “singular matrix”)。
 - 软件可能自动剔除一个变量, 导致结果不可解释。

2. 参数经济意义失效

- **逻辑矛盾:** 完全共线性的变量在现实中通常是 **同一概念的不同度量** (如 “年龄” 和 “出生年份”), 导致模型无法区分各自对因变量的独立影响。
- **示例:** 若研究收入 (y) 与教育年限 (x_1) 和学历等级 (x_2) 的关系, 而 x_2 完全由 x_1 决定 (如 本科 = 4 年, 硕士 = 6 年), 则两者的效应无法分离。

3. 统计推断完全失效

- **标准误与显著性**：即使软件强行剔除变量，剩余变量的标准误会无限大（理论上），导致：
 - t -统计量无法计算或接近零，所有系数显著性检验失效。
 - 置信区间无限宽，统计推断无意义。

不完全共线性但高度相关（多重共线性）的影响

即使不违反完全共线性假设，若自变量间 **高度相关**（如相关系数 $|\rho| > 0.8$ ），也会导致以下问题：

1. 参数估计方差增大

- **公式表达**：系数 $\hat{\beta}_j$ 的方差为：

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{SST_j(1 - R_j^2)}$$

其中 R_j^2 是 x_j 对其他自变量的回归拟合优度。

- **后果**： $R_j^2 \rightarrow 1$ 时，方差趋近于无穷大，估计值极不稳定。

2. 统计显著性失真

- **t -检验失效**：高方差导致 t -统计量 ($t = \hat{\beta}_j / \text{se}(\hat{\beta}_j)$) 绝对值减小，可能错误接受 $H_0 : \beta_j = 0$ 。
- **误判风险**：即使变量对 y 有真实影响，也可能因共线性被判定为“不显著”。

3. 系数符号与预期矛盾

- **方向反转**：高度相关的变量可能使系数符号与理论预期相反。例如：
 - 若教育年限 (x_1) 和工作经验 (x_2) 高度正相关，模型中可能出现 $\hat{\beta}_1 > 0$ 但 $\hat{\beta}_2 < 0$ 的反直觉结果。

4. 模型预测不稳健

- **样本敏感性**：微小数据变动（如删除个别观测值）可能导致系数大幅波动，模型泛化能力差。

解决方法

1. 完全共线性：

- **删除冗余变量**（如剔除 x_2 若 $x_2 = ax_1 + b$ ）。
- **合并变量**（如用“教育年限”替代“学历等级”）。

2. 多重共线性:

- 增大样本量: 降低方差, 提高估计精度。
- 主成分分析 (PCA): 将相关变量转换为正交的主成分。
- 正则化方法: 如岭回归 (Ridge Regression)、Lasso, 通过惩罚项压缩系数。
- 经济学理论指导: 优先保留理论意义明确的变量。

3. 诊断工具:

- 方差膨胀因子 (VIF): 若 $VIF > 10$, 表明严重共线性。
- 条件数 (Condition Index): 值大于 30 时需警惕。

方差的估计:

容易得到

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k - 1}$$

是 σ^2 的无偏估计量 (注: $n - k - 1$ 是模型的总自由度)

故定义标准误 (standard error):

$$se(\hat{\beta}_j) = \frac{\hat{\sigma}}{\sqrt{SST_j(1 - R_j^2)}}$$

3.7 OLS 的优良性: Gauss-Markov 定理

- (Gauss-Markov 定理) OLS 估计量是 BLUE(best linear unbiased estimator)

$$Var(\tilde{\beta}|X) \geq \sigma^2(X'X)^{-1}$$

其中 $\tilde{\beta}$ 是线性无偏估计量

3.8 拟合优度

对于多元线性回归模型, 当我们增加解释变量的个数时, R^2 一定会增加, 这可能带来过拟合的风险

因此我们有动机修正 R^2

可以定义 Adjusted R-squared (经自由度惩罚修正)

$$\bar{R}^2 = 1 - \frac{SSR/(n - k - 1)}{SST/(n - 1)}$$

它可能取到负值

4 推断与假设检验

4.1 Basics

为了进行统计推断，在之前的五条假定的基础上再补充正态性假定

- 误差 u 与 X 相互独立，服从 $N(0, \sigma^2)$

对于假设检验，基本的想法是：在原假设成立的前提下，“小概率事件”不太可能发生
由此，给出下列定义

- Type I error: 原假设为真时拒绝原假设，“弃真”
- Type II error: 原假设为假时未拒绝原假设，“取伪”

以及显著性水平

- 定义为犯第一类错误的概率
- 例如显著性水平为 0.05 表示愿意在 5% 的检验中错误地拒绝原假设

关于置信区间：

- 含义

在重复抽样下，以 95% 置信区间为例，若用相同方法构造 100 次区间，大约 95 个区间会包含参数的真实值，5 个可能不包含。

- 正确解释 vs. 常见误解
- **正确解释**：“我们有 95% 的置信度认为，这个区间包含了参数的真实值。”（强调区间构建方法的可靠性，而非参数本身的概率）
- **常见误解**：“参数有 95% 的概率落在此区间内。”（错误！参数是固定值，一旦区间计算完成，它要么包含真实值，要么不包含，不存在概率问题）

假设检验与置信区间之间的关系：

置信区间包含参数 $\Leftrightarrow$ 不拒绝零假设

4.2 T-test

T-test 用以对单个变量作单边或双边假设检验

在 Gauss-Markov 假定与正态性假定下，成立

$$T = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k-1}$$

利用该分布，可以构造相应的 t 置信区间

注：正态分布的 0.975 分位数约为 1.96；当 $DOF \geq 120$ 时，可以近似地认为 t 分布与正态分布一致

T-test 还可以对估计量的线性组合作检验

例如

$$H_0 : \beta_1 = \beta_2$$

相应的 T 统计量为

$$T = \frac{\hat{\beta}_1 - \hat{\beta}_2}{se(\hat{\beta}_1 - \hat{\beta}_2)} = \frac{\hat{\beta}_1 - \hat{\beta}_2}{\sqrt{se^2(\hat{\beta}_1) - 2s_{12} + se^2(\hat{\beta}_2)}}$$

其中 s_{12} 是对 $Cov(\hat{\beta}_1, \hat{\beta}_2)$ 的一个估计量

另一方法则是引入辅助变量 $\theta = \beta_2 - \beta_1$ 以消去原模型中 β_2, β_1 其一变量，再重新做回归，对 $H_0: \theta = 0$ 作 T 检验

4.3 F-test

F 检验的一个重要用途是**检验排除约束**

“unrestricted model” 代表原模型，“restricted model” 代表删去其中某 q 个解释变量后的回归模型

如果这 q 个解释变量作为一个整体是有效的，即相应系数并非全为 0，那么删去它们应该导致模型的解释力显著下降，也即 SSR 会显著上升

这就引出了完整的检验排除约束：

$$H_0: \beta_{i_1} = \cdots = \beta_{i_q} = 0$$

统计量

$$F = \frac{(SSR_r - SSR_{ur})/q}{SSR_{ur}/(n - k - 1)} = \frac{(R_{ur}^2 - R_r^2)/q}{(1 - R_{ur}^2)/(n - k - 1)}$$

当 F 大于临界值时，拒绝 H_0

4.4 Understanding Stata Output

```
reg wage educ
```

Source	SS	df	MS	Number of obs = 526		
Model	1179.73204	1	1179.73204	F(1, 524)	=	103.36
Residual	5980.68225	524	11.4135158	Prob > F	=	0.0000
Total	7160.41429	525	13.6388844	R-squared	=	0.1648
				Adj R-squared	=	0.1632
				Root MSE	=	3.3784

wage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
educ	.5413593	.053248	10.17	0.000	.4367534	.6459651
_cons	-.9048516	.6849678	-1.32	0.187	-2.250472	.4407687

- $SS \cdot (\cdot = Residual/Model/Total)$: 残差/模型解释了的/总的平方和

满足关系式 $SST = SSR + SSE$

- MS 指 mean square，经自由度调整的残差

满足 $SS = df \times MS$

- 检验相关

$Coeff.$ 表示相应回归的系数, $Std.Err.$ 是相应的标准误, $t = \frac{Coef.}{Std.Err.}$

$P > |t|$ 指 t 检验中的双侧 P 值

补充: P 值定义

P 值是统计假设检验中的核心概念, 其数学定义可严格表述如下:

P 值是在原假设 H_0 成立的条件下, 检验统计量 T 出现当前观测值或更极端值的概率。具体形式依赖于检验方向:

1. 右侧检验 ($H_1: \theta > \theta_0$):

$$P\text{-value} = P(T \geq t \mid H_0)$$

2. 左侧检验 ($H_1: \theta < \theta_0$):

$$P\text{-value} = P(T \leq t \mid H_0)$$

3. 双侧检验 ($H_1: \theta \neq \theta_0$):

$$P\text{-value} = 2 \cdot \min \{P(T \leq t \mid H_0), P(T \geq t \mid H_0)\}$$

特别地, 对于对称的 t 分布, 若单边备择方向与观测统计量方向一致, 双边检验的 P 值除以 2 可得到对应的单边 P 值

直观而言, 一个很小的 P 值是拒绝原假设的很强证据

补充: T 检验与 F 检验

注意到图表中 $t_{educ}^2 = F$, 事实上有以下结论:

在多元线性回归中, 单个变量假设排除检验的 F 统计量等于 t 统计量的平方

1. 模型设定与假设检验目标

考虑多元线性回归模型:

$$Y = X\beta + \epsilon$$

其中:

- X 是 $n \times (k+1)$ 的设计矩阵 (包含 k 个自变量和截距项)。
- 要检验第 j 个自变量是否应被排除, 即原假设 $H_0: \beta_j = 0$ 。

2. 构造统计量

(1) t 统计量

- 系数估计: $\hat{\beta}_j$ 是第 j 个自变量的最小二乘估计。
- 标准误: $\text{SE}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 \cdot (X_j^T M_{-j} X_j)^{-1}}$, 其中 M_{-j} 是排除第 j 个变量后的投影矩阵。
- t 统计量: $t = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t(n - k - 1)$

(2) F 统计量

- 无约束模型 (包含所有变量): 残差平方和为 SSR_u 。
- 受约束模型 (排除第 j 个变量): 残差平方和为 SSR_r 。
- F 统计量: $F = \frac{(\text{SSR}_r - \text{SSR}_u)/1}{\text{SSR}_u/(n-k-1)} \sim F(1, n - k - 1)$

3. 数学推导: 证明 $F = t^2$

1. 残差平方和之差: 根据线性回归理论, 排除变量 j 导致的残差平方和增加为:

$$\text{SSR}_r - \text{SSR}_u = \hat{\beta}_j^2 \cdot (X_j^T M_{-j} X_j)$$

2. t 统计量的平方:

$$t^2 = \frac{\hat{\beta}_j^2}{\text{SE}(\hat{\beta}_j)^2} = \frac{\hat{\beta}_j^2}{\hat{\sigma}^2 \cdot (X_j^T M_{-j} X_j)^{-1}}$$

3. 代入 F 统计量公式:

$$F = \frac{\hat{\beta}_j^2 \cdot (X_j^T M_{-j} X_j)}{\hat{\sigma}^2} = t^2$$

- 分母: $\hat{\sigma}^2 = \text{SSR}_u/(n - k - 1)$ 。
- 分子: $\text{SSR}_r - \text{SSR}_u = \hat{\beta}_j^2 \cdot (X_j^T M_{-j} X_j)$ 。

5 大样本特性——Asymptotics

5.1 Why we care about asymptotics?

在很多情况下, 对样本的分布, 我们缺乏很多信息——同方差、正态假设过强而未必符合事实。但是, 我们依旧需要知道估计量是否是准的、怎么作检验等等一系列问题。因此, 大样本的渐进特性为这些问题提供了分析框架, 使得很多检验等在缺乏正态、同方差等假定的条件下依旧是渐进有效的。

5.2 Consistency——一致性

在这一主题下, 一致性即指弱相合性

$$\lim_{n \rightarrow \infty} \mathbb{P}(|f_n - f| \geq \varepsilon) = 0, \forall \varepsilon > 0$$

- *THM* 在假定一至假定四下, OLS 估计量是一致的

证明概要

以简单二元回归为例

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1 + \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})u_i}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

由弱大数律即得

$$\hat{\beta}_1 \xrightarrow{P} \beta_1 + \frac{Cov(x, u)}{Var(x)}$$

- *THM* Under MLR.1 through MLR.5, we have:

- $\sqrt{n}(\hat{\beta}_j - \beta_j) \xrightarrow{d} N(0, \sigma^2/a_j^2)$, where $a_j^2 = \text{plim} \left(n^{-1} \sum_{i=1}^n \hat{r}_{ij}^2 \right)$ (residuals from auxiliary regression)
- $\hat{\sigma}^2$ is consistent for $\sigma^2 = Var(u)$
- For each j , we have

$$\frac{\hat{\beta}_j - \beta_j}{sd(\hat{\beta}_j)} \xrightarrow{d} N(0, 1)$$

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \xrightarrow{d} N(0, 1)$$

Some notes:

MLR.5, i.e. homoskedasticity is crucial for the proof;

the variance shrinks at the rate $Var(\hat{\beta}_j) = O(\frac{1}{n})$

6 其他

6.1 Data Scaling

6.2 Beta Coefficients/Standardization

6.3 Models with Quadratics

Model:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + u$$

Then we have

$$\frac{dy}{dx} = \beta_1 + 2\beta_2 x$$

which means the partial effect depends on the value of x

Easily we can derive the turning point of y $x^* = -\frac{\beta_1}{2\beta_2}$

And in practice we need to consider the range of the data to see whether y really turns.

6.4 Models with Interaction Terms

7 异方差

7.1 影响

异方差并不会影响 OLS 估计的一致性、无偏性，因为它们只依赖于假定一至假定四（主要是条件期望零值假定 $\mathbb{E}(u|x) = 0$ ）

R^2 或是 $\text{adjusted } R^2$ 也依旧是好的衡量拟合优度的标准

但是常规方差估计与标准误失效了，这也意味着 T-test、F-test 均失效了

同时，OLS 估计量也不再是 BLUE 了

7.2 方差

以简单二元回归为例

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\Rightarrow$$

$$\text{Var}(\hat{\beta}_1|X) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \sigma_i^2}{SST_x^2}$$

根据 White 的结论

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{SST_x^2}$$

是 $\text{Var}(\hat{\beta}_1|X)$ 的合适估计量

对于多元回归的情形，则成立

$$\text{Var}(\hat{\beta}_j|X) = \frac{\sum_{i=1}^n \hat{r}_{ij}^2 \sigma_i^2}{\left(\sum_{i=1}^n \hat{r}_{ij}^2\right)^2}$$

对应的估计量则为

$$\frac{\sum_{i=1}^n \hat{r}_{ij}^2 \hat{u}_i^2}{\left(\sum_{i=1}^n \hat{r}_{ij}^2\right)^2}$$

7.3 稳健标准误

根据 White 的结果，我们可以使用稳健标准误来进行统计推断
一些概念性的结论：

- 稳健标准误与常规标准误的大小关系不确定
- 稳健标准误的实用性依赖于大样本

7.4 异方差的检验

- Breusch-Pagan Test

假定一至四成立，模型为

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u$$

直觉上, 想要检验

$$H_0: \mathbb{E}(u^2|x_1, \dots, x_k) = \sigma^2$$

我们假定 u^2 与 x_i 呈线性关系

$$u^2 = \delta_0 + \delta_1 x_1 + \dots + \delta_k x_k + v$$

于是, 正式的原假设变为

$$H_0: \delta_1 = \dots = \delta_k = 0$$

用原模型回归得到残差 $\hat{u}_i$ 后, 再将 $\hat{u}_i^2$ 对 $x_1, \dots, x_k$ 回归, 得到 $R_{\hat{u}^2}^2$

计算 F 统计量

$$F = \frac{R_{\hat{u}^2}^2/k}{(1 - R_{\hat{u}^2}^2)/(n - k - 1)}$$

在零假设下渐进服从 $F_{k, n-k-1}$ (注: 对常数回归得到的 R^2, SSE 均为 0)

当然, 如果仅仅怀疑异方差只对于某些解释变量成立, 可以在第二步回归中将残差仅仅对于这些解释变量回归

7.5 加权最小二乘法

如果我们知道了一些关于异方差结构的信息, 就可以通过调整系数将原模型转化为具有同方差的新模型, 此时 t 统计量、F 统计量具有 t 分布、F 分布

具体操作如下:

对原回归模型归一化

$$\begin{aligned} y_i &= \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + u_i \\ &\quad \text{两侧同时除以 } \sqrt{h_i} \\ &\quad \rightarrow \\ y_i^* &= \beta_0 x_{i0}^* + \beta_1 x_{i1}^* + \dots + \beta_k x_{ik}^* + u_i^*, \quad x_{i0}^* = \frac{1}{\sqrt{h_i}} \end{aligned}$$

对于新的模型

$$\begin{aligned} \mathbb{E}(u_i^*|X_i) &= 0 \\ \text{Var}(u_i^*|X_i) &= \frac{1}{h_i} \text{Var}(u_i|X_i) = \sigma^2 \end{aligned}$$

对新的模型进行 OLS 回归

$$\min \sum_{i=1}^n (y_i^* - \beta_0^* - \beta_1 x_{i1}^* - \dots - \beta_k x_{ik}^*)^2$$

也即

$$\min \sum_{i=1}^n \frac{1}{h_i} (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_k x_{ik})^2$$

系数 $\frac{1}{h_i}$ 可以视作对每个残差项的权重, 故上述方法称作加权最小二乘估计 (WLS)

更进一步地, 为了估计 $\frac{1}{h_i}$, 我们引进 FGLS (feasible generalized least square):

先使用 OLS 估计得到残差项 $\hat{u}_i$

假定方差具有形式

$$\text{Var}(u_i|X_i) = \sigma^2 h(X_i)$$

例如 $h(X_i) = \exp(\alpha_0 + \alpha_1 x_1 + \cdots + \alpha_k x_k)$

利用 OLS 得到 $h(X_i)$ 的估计量，再利用该估计量进行 WLS

Part II

Part II

8 模型规范与数据

当零条件均值不成立时，我们需要更进一步的方法做处理，这就是本节讨论的起点

8.1 代理变量 (Proxy variables)

遗漏变量会对估计造成较大的偏误，而代理变量就是与未观察到变量相关的一个变量

以下是一个具体的实例：

考虑模型

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3^* + u$$

其中 x_3^* 不可观测，满足

$$x_3^* = \delta_0 + \delta_3 x_3 + v_3$$

带回原模型，有

$$\begin{aligned} y &= (\beta_0 + \beta_3 \delta_0) + \beta_1 x_1 + \beta_2 x_2 + \beta_3 \delta_3 x_3 + (\beta_3 v_3 + u) \\ &= \tilde{\beta}_0 + \beta_1 x_1 + \beta_2 x_2 + \tilde{\beta}_3 x_3 + \varepsilon \end{aligned}$$

从而，在一定的条件下， β_1, β_2 是能够被一致地估计的

- $\mathbb{E}(u|x_1, x_2, x_3^*) = \mathbb{E}(u|x_1, x_2, \delta_0 + \delta_3 x_3 + v_3) = 0$

因此，需要 u 与 x_1, x_2, x_3, v_3 不相关

- $\mathbb{E}(\varepsilon|x_1, x_2, x_3) = \mathbb{E}(\beta_3 v_3 + u|x_1, x_2, x_3) = 0$

因此需要 v_3 与 x_1, x_2, x_3 不相关

总之，对于该实例，一个好的代理变量须满足以下三条：

- $\mathbb{E}(u|x_1, x_2, x_3) = 0$
- $\mathbb{E}(v|x_1, x_2, x_3) = 0$
- $\delta_3 \neq 0$

难以找到合适的代理变量时，也可以使用因变量的滞后项（通常使用很久以前的变量）作为代理变量

8.2 测量误差

8.2.1 因变量情形

考虑我们感兴趣的一个变量 y^* ， y 是其报告值，则测量误差定义为 $e_0 = y - y^*$ ，那么

- e_0 与自变量相关时，OLS 就将是偏的
- e_0 与自变量无关时，OLS 估计量仍然是一致与无偏的
- e_0, u 无关时， $\text{Var}(e_0 + u) = \sigma_u^2 + \sigma_e^2$ ，也就是说，方差要比一般情形更高

8.2.2 自变量情形

想要估计的模型是

$$y = \beta_0 + \beta_1 x_1^* + u$$

自变量 x_1^* 存在测量误差 $e_1 = x_1 - x_1^*$

那么，我们实际在估计的模型是

$$y = \beta_0 + \beta_1 x_1 + u - \beta_1 e_1$$

若 $Cov(x_1, e_1) = 0$ ，则得到的 OLS 估计是无偏的

但是，若成立 $Cov(x_1^*, e_1) = 0$ ，即经典的含误差变量假设，那么

$$Cov(x_1, e_1) = Cov(x_1^*, e_1) + Cov(e_1, e_1) = \sigma_e^2$$

进而

$$\begin{aligned} \text{plim} \hat{\beta}_1 &= \beta_1 + \frac{Cov(x_1, u - \beta_1 e_1)}{Var(x_1)} \\ &= \beta_1 - \frac{\beta_1 \sigma_e^2}{\sigma_{x^*}^2 + \sigma_e^2} = \beta_1 \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_e^2} \end{aligned}$$

也就是估计量会系统性地向下偏小，这被称为**衰减偏误 (attenuation bias)**

在多元回归的情形中，衰减偏误仍然存在

8.3 数据缺失

8.3.1 MCAR

我们考虑 MCAR 的情形（注：missing completely at random，相对应的情形则是——缺失的数据与 x 或 y 的取值相关，比如富裕家庭不愿意报告自己的收入）

处理的方法通常是使用 MIM——Missing Indicator Method，具体而言：

假定 x_{ik} 对某些 i 是丢失的，那么我们定义两个虚拟变量

$$\begin{aligned} \bullet \quad Z_{ik} &= \begin{cases} x_{ik}, & \text{observed} \\ 0, & \text{else} \end{cases} \\ \bullet \quad m_{ik} &= \begin{cases} 1, & \text{missing} \\ 0, & \text{else} \end{cases} \end{aligned}$$

将原模型：

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u$$

替换为：

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_{k-1} x_{k-1} + \gamma Z_k + \delta m_k + u$$

然后进行 OLS 回归，得到

- γ ： x_k 的估计系数（与非缺失样本一致）
- δ ：缺失组的截距偏移量（反映缺失组与非缺失组的系统性差异）

具体地，可能有以下几种情形：

Case 1: δ 不显著

- **含义：** 缺失组与非缺失组无系统性差异
- **推论：** 数据可能满足 MCAR, γ 解释为总体效应

Case 2: δ 显著但 γ 稳定

- **解释（示例）：**
 - 存在系统性差异：IQ 缺失人群工资平均低 15%
 - 但 IQ 对工资的边际效应 (4%) 在非缺失组可靠
- **政策含义（示例）：**
 - 对可观测人群：提升 IQ 可增加工资
 - 对缺失人群：需针对性干预（如培训）

Case 3: δ 与 γ 均显著且符号相反

- **警告：** 可能存在**选择偏差**
 - 解释：高能力者（应高工资）更可能隐藏 IQ $\rightarrow$ 缺失组实际能力被低估

MIM 中估计量的无偏性与一致性需有以下两条成立：

- MCAR
- x_{ik} 与其他自变量 $x_1, \dots, x_{k-1}$ 不相关

8.3.2 非随机样本

- **外生选择：** 基于解释变量 x 抽样（如分层抽样中过度抽样女性） $\rightarrow$ OLS 无偏。
- **内生选择：** 基于被解释变量 y 抽样（如仅调查低犯罪率城市） $\rightarrow$ **选择偏误**。

8.4 离群值

小样本中，OLS 估计量容易受极端数据——离群值——的影响，以下是几种处理方法：

- 舍弃离群点
- 将数据变换为对离群点较为不敏感的函数形式，如取对数
- 缩尾（Winsorization）

将超过某个阈值（bar）的值全部记录为该阈值

- 稳健估计方法

其中一种方法是 LAD (least absolute deviation, 从属于一类更广泛的估计方法——分位数回归)，具体而言，其优化模型是

$$\min_{\beta} \sum_{i=1}^n |y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_k x_{ik}|$$

9 时间序列分析

9.1 基础概念

时间序列数据的本质

- **随机过程**：按时间索引的随机变量序列。
- **时间序列数据**：随机过程的一次实现——样本空间中的一条轨道 ω 。
- **样本容量**：时间期数 (T)。
- **总体**：随机过程所有可能的实现，即样本空间 Ω 。

9.2 经典模型

9.2.1 静态模型 (Static Model)

示例：

$$y_t = \beta_0 + \beta_1 z_t + u_t, \quad t = 1, \dots, T$$

也即所有变量都在同一个时间段内

9.2.2 分布滞后模型 (Finite Distributed Lag Model)

示例 (滞后 2 阶)：

$$y_t = \alpha_0 + \delta_0 z_t + \delta_1 z_{t-1} + \delta_2 z_{t-2} + u_t$$

- 即期效应 (Impact Multiplier): δ_0
- 长期效应 (Long-Run Propensity, LRP)

对于滞后 q 阶的模型

$$LRP = \delta_0 + \delta_1 + \dots + \delta_q$$

具体而言，当 z 发生了永久性变化——从基期水平 c 永久增加 1 单位，那么发生变化之前

$$y_{t-1} = \alpha_0 + \delta_0 c + \delta_1 c + \dots + \delta_q c$$

滞后 q 期以后，所有 z 均变为 $c + 1$

$$y_{t+s} = \alpha_0 + \delta_0(c+1) + \delta_1(c+1) + \dots + \delta_q(c+1) \quad s \geq q$$

故 $\lim_{t \rightarrow \infty} \Delta y_t = \delta_0 + \dots + \delta_q$ ，也就是 LRP

对于滞后模型，有以下注意事项：

- 因变量、自变量一般要在同一“阶”上，不同阶的变量可以通过取对数保持阶的一致
- 滞后的阶数可通过 F 检验来确定

9.2.3 事件研究模型 (Event Study Model)

示例：

$$Y_{i,t} = \alpha_i + \sum_{k=-3}^3 \mu_k D_{i,t}^k + \nu_{i,t}$$

其中， $D_{i,t}^k$ 是事件发生前后各期的虚拟变量

上角标表示发生的“期数”，例如 $k = -3$ 表示发生前 3 期

9.3 OLS 性质

9.3.1 无偏性

引入三条假定：

- Assumption TS.1: linear in parameters
- Assumption TS.2: No perfect collinearity
- Assumption TS.3: Zero conditional mean

$$\mathbb{E}(u_t|X) = 0$$

其中, X 包含了所有过去、现在、未来的自变量, 因此被称为严格外生假定 (**strictly exogenous**)

当以上三条假定成立时, 可以证明, OLS 估计量是条件无偏的, 进而是无偏的
相对应的, 也有弱外生性假定:

- $\mathbb{E}(u_t|X_t) = 0$
- $\mathbb{E}(u_t|X_0, \dots, X_t) = 0$

9.3.2 方差

- Assumption TS.4: Homoskedasticity in error terms
- Assumption TS.5: No Serial Correlation

$$\rho(u_t, u_s|X) = 0, \quad \forall t \neq s$$

在以上五条假定下, 类似于多元线性回归模型, 成立

- $Var(\hat{\beta}_j|X) = \frac{\sigma^2}{SST_j(1 - R_j^2)}, j = 1, \dots, k$
- $\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n - k - 1}$ 是 σ^2 的无偏估计
- Gauss-Markov 定理成立, 即 OLS 估计量是 BLUE (best-linear-unbiased estimator)

9.3.3 正态性

- Assumption TS.6: Normality

u_t 与 X 独立, 且 $u_t \stackrel{i.i.d}{\sim} N(0, \sigma^2)$

在正态性假定下, 估计量的 F/t 统计量分别服从 F/t 分布

9.4 趋势与季节性

两个趋势变量回归可能导致高 R^2 , 但实际无因果关系, 因此需要去趋势 (detrending), 然后利用 FWL 定理两步回归 (或是在原模型中引入时间趋势项后直接回归)

以下是几种基本模型:

- **线性趋势**: $y_t = \alpha_0 + \alpha_1 t + e_t$
- **指数趋势**: $\log y_t = \beta_0 + \beta_1 t + e_t$
- **二次趋势**: $y_t = \alpha_0 + \alpha_1 t + \alpha_2 t^2 + e_t$

至于季节性 (Seasonality), 则简单地可以引入季度/月度的虚拟变量来进行控制

9.5 自回归模型

9.5.1 Granger 检验

通过一个简单的例子来进行说明——“先有鸡还是先有蛋”

给出两个模型

- $eggs_t = \mu + \alpha_1 \cdot eggs_{t-1} + \beta_1 \cdot chickens_{t-1} + \varepsilon_t$
- $chickens_t = \mu + \alpha_2 \cdot chickens_{t-1} + \beta_2 \cdot eggs_{t-1} + \varepsilon_t$

在 Granger 检验中, 是否先有鸡的证据就是要检验 $H_0: \beta_1 = 0$

相应的, 是否先有蛋的证据则是检验 $H'_0: \beta_2 = 0$

如果假设检验拒绝了 H'_0 而没有拒绝 H_0 , 则我们发现了先有蛋的证据

9.5.2 自回归模型——序列误差相关的情形

模型 考虑模型

$$y_t = \beta_0 + \beta_1 x_{1t} + \cdots + \beta_k x_{kt} + u_t$$

该模型被称作具有序列相关的误差, 如果

$$u_t = \rho_1 u_{t-1} + \cdots + \rho_q u_{t-q} + e_t$$

其中 $e_t \stackrel{i.i.d.}{\sim} N(0, \sigma_e^2)$

将 u_t 称作 q 阶自回归, 记作 $AR(q)$

通常情况下, 我们考虑 $AR(1)$

当 $|\rho| < 1$ 时, 我们称 $\{u_t\}$ 是一个稳定的过程 (注: 从几何级数的观点看, 这是自然的)

OLS 性质 在此条件下, TS.1 至 TS.3 仍然成立, 故 OLS 是一致与无偏的

但是, 由于 $Cov(u_t, u_s) = 0$ 不再成立, 故 OLS 不再是 BLUE, 且标准误与检验统计量也不再有效

方差 考虑模型

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

为简单起见, 令 $\bar{x} = 0$

则

$$\begin{aligned} Var(\hat{\beta}_1) &= Var\left(\beta_1 + \frac{\sum_{t=1}^T x_t u_t}{\sum_{t=1}^T x_t^2}\right) \\ &= \frac{1}{\left(\sum_{t=1}^T x_t^2\right)^2} Var\left(\sum_{t=1}^T x_t u_t\right) \end{aligned}$$

而

$$Var\left(\sum_{t=1}^T x_t u_t\right) = \sum_{t=1}^T x_t^2 Var(u_t) + 2 \sum_{t=1}^{T-1} \sum_{j=1}^{T-t} x_t x_{t+j} \mathbb{E}(u_t u_{t+j})$$

在同方差假定下 $Var(u_t) = \sigma_u^2$

再考虑第二项

$$\begin{aligned} u_{t+j} &= \rho u_{t+j-1} + e_{t+j} = \rho(\rho u_{t+j-2} + e_{t+j-1}) + e_{t+j} = \\ &\quad \dots \\ &= \rho^j u_t + \rho^{j-1} e_{t+1} + \dots + \rho e_{t+j-1} + e_{t+j} \end{aligned}$$

由 $e_t \stackrel{i.i.d.}{\sim} N(0, \sigma_e^2)$ 可得

$$\mathbb{E}(u_{t+j} u_t) = \rho^j \sigma_u^2$$

带入即得 $Var(\hat{\beta}_1)$

因此，当 $\rho > 0$ 且解释变量在相邻期通常同向变动时，常规 OLS 方差往往低估真实方差
因此 t 统计量也不再正确


10 定性信息建模

10.1 单虚拟变量

以一个简单的模型为例

$$wage = \beta_0 + \delta_0 female + \beta_1 educ + u$$

在零条件均值假定下，易知 δ_0 是两组之间的截距差



再考虑一个更为特殊的情形

$$y_i = \beta_0 + \beta_1 d_i + u, \quad i = 1, \dots, n$$

其中 d_i 是取值 0/1 的虚拟变量

斜率系数的 OLS 估计具有以下简单的形式：

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sum_{i=1}^n (d_i - \bar{d}) y_i}{\sum_{i=1}^n (d_i - \bar{d})^2} \\ &= \frac{\sum_{d=1} \left(1 - \frac{n_1}{n}\right) y_i + \sum_{d=0} \left(0 - \frac{n_1}{n}\right) y_i}{\sum_{d=1} \left(1 - \frac{n_1}{n}\right)^2 + \sum_{d=0} \left(0 - \frac{n_1}{n}\right)^2} \\ &= \frac{\sum_{d=1} y_i}{n_1} - \frac{\sum_{d=0} y_i}{n - n_1}\end{aligned}$$

10.2 虚拟变量间交互

10.2.1 DID (difference in differences)

DID 是一种通过两个 0-1 虚拟变量交互所得的模型，通常用以衡量某一政策实施的效果。它通过比较“处理组”与“控制组”在政策实施前后的变化差异，来“双重”地剔除混杂因素，从而识别出政策的净效应。

考虑一个两期数据的具体模型

$$y_{it} = \beta_0 + \beta_1 D_t + \beta_2 G_i + \beta_3 D_t G_i + u$$

其中

$$D_t = \begin{cases} 1, & \text{post-policy} \\ 0, & \text{pre-policy} \end{cases}$$

$$G_i = \begin{cases} 1, & \text{treated} \\ 0, & \text{control} \end{cases}$$

于是，实验对象被分为了四组，各组的系数分别为

$E(y_{it} D_t, G_i)$	$G_i = 0$	$G_i = 1$
$D_t = 0$	β_0 (*)	$\beta_0 + \beta_2$ (***)
$D_t = 1$	$\beta_0 + \beta_1$ (**)	$\beta_0 + \beta_1 + \beta_2 + \beta_3$ (****)

于是， β_3 具有如下双重差分式的解释

$$\beta_3 = [(\text{****}) - (\text{***})] - [(\text{**}) - (*)]$$

更一般的 DID 模型通常通过面板模型来实现

10.2.2 其他模型

虚拟变量还有多种交互方式。例如，在下面的例子中，虚拟变量可以与连续的变量相交互，表示组间的斜率差

$$\log wage = \beta_0 + \delta_0 female + \beta_1 edu + \delta_1 female \cdot edu + u$$

然后就可以根据系数的具体含义来做假设检验

例如，“教育年限对于工资的影响与性别无关”对应的零假设为 $H_0: \delta_1 = 0$

可以用 t 统计量或是 F 统计量来具体检验

更一般地, 对于组间的各种差距, 我们有如下的检验方法

10.2.3 邹检验 (Chow-test)

考虑一个两组 ($g = 1, g = 2$) 的模型如下

$$y = \beta_{g,0} + \beta_{g,1}x_1 + \cdots + \beta_{g,k}x_k + u$$

要检验的原假设为 H_0 : 两组之间的回归方程一致, 精确而言

$$H_0: \beta_{1,i} = \beta_{2,i}, \quad i = 0, 1, \dots, k$$

为进行检验, 分别进行两组回归

- 合并回归 (restricted model)

将两组数据合并, 进行回归, 得到残差项平方和 SSR_r

- 分组回归 (unrestricted model)

为第一组、第二组数据分别单独估计一个回归方程, 得到两个残差项平方和 SSR_1, SSR_2 。于是 $SSR_{ur} = SSR_1 + SSR_2$

进而得到邹氏统计量

$$\begin{aligned} F &= \frac{(SSR_r - SSR_{ur}) / (DOF_r - DOF_{ur})}{SSR_{ur} / DOF_{ur}} \\ &= \frac{(SSR_r - SSR_1 - SSR_2) / (k + 1)}{(SSR_1 + SSR_2) / [n - 2(k + 1)]} \end{aligned}$$

10.3 注意事项

多分类变量 (Multiple Categories):

- 如果一个分类变量有 n 个类别 (如四个季度), 为了避免“虚拟变量陷阱” (完全多重共线性), 我们应该在回归中引入 $n - 1$ 个虚拟变量。

定序变量 (Ordinal Information):

- 定序变量 (如信用评级、课程评价“差、中、好、优”) 的值有顺序但数值本身没有定量意义。
- 直接将它们作为 1,2,3,4 这样的连续变量放入模型是不妥当的, 因为这隐含了“从 1 到 2”和“从 2 到 3”的影响是相同的假设, 而这通常不成立。
- **正确做法:** 为每个类别设置虚拟变量 (或根据研究需要将几个类别合并), 然后将这些虚拟变量作为自变量放入模型。

10.4 概率模型

10.4.1 线性概率模型 (LPM, linear probability model)

当因变量是二元 (0 或 1) 定性变量时 (如是否就业、是否结婚), 我们可以使用 LPM。

- 模型形式:

$$y = \beta_0 + \beta_1x_1 + \cdots + \beta_kx_k + u$$

由于 y 只能取 0 或 1，其条件期望等于

$$\mathbb{E}(y|x) = \mathbb{P}(y = 1|x)$$

因此，模型可以写成：

$$\mathbb{P}(y = 1|x) = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

这个条件概率也被称为“响应概率”“倾向性得分 (propensity score)”。

系数 β_j 的解释是：在其他条件不变的情况下， x_j 每增加一个单位，因变量 $y = 1$ 的概率会改变 β_j 。

• **LPM 的固有问题：**

1. **概率越界：**模型预测出的概率可能小于 0 或大于 1，这在现实中是不可能的。
2. **边际效应恒定：**模型假设自变量对概率的影响是线性的、恒定的。但现实中，当概率已经很高或很低时，自变量再变化相同幅度，其对概率的影响可能会减弱。例如，从 0 个孩子增加到 1 个，和从 5 个增加到 6 个，对劳动参与概率的影响可能不同。
3. **异方差性：**当因变量是二元变量时，误差项的方差必然是异方差的，因为 $\text{Var}(y|x) = p(x)[1 - p(x)]$ ，它会随着 $p(x)$ （也就是自变量 x ）的变化而变化。这会导致 OLS 估计的标准误和 t、F 统计量失效，需要谨慎解释，但是 OLS 估计的系数仍然是无偏的。

10.4.2 Logit 和 Probit 模型

为了克服 LPM 模型的缺陷，可以引入 Logit 和 Probit 模型

• **模型形式**

Logit 模型：使用 Logistic 函数的 CDF

$$\mathbb{P}(y = 1|x) = \frac{1}{1 + \exp(-x\beta)}$$

Probit 模型：使用标准正态分布的 CDF

$$\mathbb{P}(y = 1|x) = \Phi(x\beta)$$

注意，这两个模型的边际效应是非恒定的，但其符号通常与 β_i 的符号是一致的

10.5 其他

10.5.1 经济显著性与统计显著性

统计显著性 (Statistical Significance) 回答的是：“我们观察到的效应有多大的可能性是真实存在的，而不是由随机误差或抽样偶然性造成的？”

- **衡量标准：**它由统计检验（如 t 检验或 F 检验）的结果来判断。我们通常关注 p 值或 t 统计量的大小。
- **核心意义：**统计显著性告诉我们，我们有信心拒绝“该变量的真实影响为零”的原假设。它关注的是效应存在的**确定性**。

经济显著性 (Economic Significance) 回答的是：“这个效应的幅度（大小）在现实世界中是否足够大，以至于具有实际意义或重要性？”

- **衡量标准：**它通过解读回归系数的大小来判断。

- 判断方法：这需要结合经济理论和现实背景进行主观判断。例如，一个政策能让 GDP 增长 0.001%，即使这个结果在统计上非常显著，但在经济上可能微不足道。
- 核心意义：经济显著性关注的是效应的量级和实际价值。

10.5.2 不显著的变量？

实际回归中，我们未必会删去不显著的回归变量，以下是几点考虑：

- 避免遗漏变量偏误
- 在 F 检验中，一组变量可能单个来看都不显著，但它们作为一个整体对因变量有显著影响
- “insignificance” 本身也是可讲的故事

11 面板数据

11.1 面板数据基础

面板数据是在一段时间内跟踪同一个样本个体的数据集，从而可以对样本中的每个个体进行多次观测。

其优势、劣势如下

优势

1. **更精确的模型参数推断**：面板数据通常为研究者提供大量的观测点，这增加了自由度，并减少了解释变量之间的共线性，从而提高了计量经济学估计的效率。
2. **为宏观数据分析提供微观基础**：在宏观分析中，经济学家常使用“代表性个体”的假设。而面板数据允许我们通过聚合微观方程来预测宏观结果，这种预测可能比直接使用宏观数据更准确。

挑战

1. 异质性偏误 (Heterogeneity Bias)

面板数据的理论优势基于一个假设，即经济数据是在受控实验中生成的。但如果这个假设是错误的，就会产生异质性偏误。这意味着不同个体或截面单位之间存在未被观测到的差异。

2. 选择性偏误 (Selectivity Bias)

当样本不再是总体的随机抽取时，就会产生样本选择偏误。

损耗偏误 (Attrition Bias)：这是选择性偏误的一种，指在数据收集过程中，部分样本因各种原因退出，导致最终样本失去随机性。

当样本的筛选（或截断）与被解释变量相关时，也会导致严重的偏误。

11.2 模型

11.2.1 固定效应模型

$$y_{it} = \alpha_i + \beta' x_{it} + u_{it}$$

$$i = 1, 2, \dots, N; t = 1, 2, \dots, T$$

假设：误差项 u_{it} 独立同分布，零均值，方差为 σ_u^2 ，且与 x_{it} 无关

根据 OLS 的想法, 为估计各参数, 我们的优化问题为

$$\min \sum_{i=1}^N \sum_{t=1}^T (y_{it} - \alpha_i - \beta' x_{it})^2$$

打开求和号, 待优化式的具体形式为

$$\begin{aligned} S = & (y_{11} - \alpha_1 - \beta' x_{11})^2 + \cdots + (y_{1T} - \alpha_1 - \beta' x_{1T})^2 \\ & + \cdots \\ & + (y_{N1} - \alpha_N - \beta' x_{N1})^2 + \cdots + (y_{NT} - \alpha_N - \beta' x_{NT})^2 \end{aligned}$$

关于 α_i 的一阶条件为

$$\sum_{t=1}^T (y_{it} - \alpha_i - \beta' x_{it}) = 0, \quad i = 1, \dots, N$$

故

$$\alpha_i = \bar{y}_i - \beta' \bar{x}_i, \quad i = 1, \dots, N$$

其中的平均是对时间的平均

再求关于 β 的一阶条件, 得

$$\sum_{i=1}^N \sum_{t=1}^T (y_{it} - \alpha_i - x_{it}' \beta) x_{it} = 0$$

带入 α_i 的表达式, 得

$$\sum_{i=1}^N \sum_{t=1}^T [(y_{it} - \bar{y}_i) - (x_{it} - \bar{x}_i)' \beta] (x_{it} - \bar{x}_i) = 0$$

解出

$$\hat{\beta}_{FE} = \left[\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x}_i)(x_{it} - \bar{x}_i)' \right]^{-1} \sum_{i=1}^N \sum_{t=1}^T (y_{it} - \bar{y}_i)(x_{it} - \bar{x}_i)$$

该估计量被称为组内估计量 (within estimator); 它与加入个体虚拟变量的 LSDV (least-squares dummy-variable) 估计在斜率系数上等价

注: dummy-variable 实际上指的是模型与下列模型等价

$$y_{it} = \sum_{k=1}^N D_k \alpha_k + \beta' x_{it} + u_{it}$$

其中 $D_k = 1_{\{k=i\}}$

对于固定效应模型还有一种估计方法——差分估计法

以 $T = 2$ 为例

$$\begin{aligned} y_{it} &= \alpha_i + \beta' x_{it} + u_{it} \\ i &= 1, \dots, N; t = 1, 2 \end{aligned}$$

定义 $\Delta y_i = y_{i2} - y_{i1}, \Delta x_i = x_{i2} - x_{i1}$

定义 β 的差分估计量为

$$\hat{\beta}_{FD} = \left(\sum_{i=1}^N \Delta x_i \Delta x_i' \right)^{-1} \sum_{i=1}^N \Delta x_i \Delta y_i$$

可以证明, 对于 $T = 2$ 的情形, $\hat{\beta}_{FE} = \hat{\beta}_{FD}$:

由关于 α_i 的一阶条件

$$\begin{aligned} \sum_{i=1}^N [(y_{i1} - \alpha_i - \beta' x_{i1})^2 + (y_{i2} - \alpha_i - \beta' x_{i2})^2] \\ = \frac{1}{2} \sum_{i=1}^N (\Delta y_i - \beta' \Delta x_i)^2 \end{aligned}$$

从而 FE 与 FD 的优化函数仅相差一个正常数因子, 得到的参数估计是一致的

11.2.2 随机效应模型

随机效应模型具有以下形式

$$\begin{aligned} y_{it} = \mu + \beta' x_{it} + v_{it}, \quad v_{it} = \alpha_i + \lambda_t + u_{it} \\ i = 1, \dots, N; t = 1, \dots, T \end{aligned}$$

对误差项做如下假定

$$\begin{aligned} \mathbb{E}\alpha_i &= \mathbb{E}\lambda_t = \mathbb{E}u_{it} = 0 \\ \mathbb{E}\alpha_i \lambda_t &= \mathbb{E}\alpha_i u_{it} = \mathbb{E}\lambda_t u_{it} = 0 \\ \mathbb{E}\alpha_i \alpha_j &= \begin{cases} \sigma_a^2, & i = j \\ 0, & else \end{cases} \\ \mathbb{E}\lambda_t \lambda_s &= \begin{cases} \sigma_\lambda^2, & s = t \\ 0, & else \end{cases} \\ \mathbb{E}u_{it} u_{js} &= \begin{cases} \sigma_u^2, & i = j, t = s \\ 0, & else \end{cases} \end{aligned}$$

且

$$\mathbb{E}\alpha_i x_{it} = \mathbb{E}\lambda_t x_{it} = \mathbb{E}u_{it} x_{it} = 0$$

对于 RE 模型, 可以采用矩方法估计参数

注: RE 是否成立通常通过 Hausman 检验来检验, 相应的零假设为 H_0 : 个体效应与解释变量无关

12 工具变量

12.1 引入

考虑一个简单的一元回归模型

$$y = \beta_0 + \beta_1 x + u$$

在 OLS 方法中, 为了获得一致、无偏的估计量, 我们需要要求 $\mathbb{E}(u|x) = 0$, 也即解释变量 x 与误差项 u 是不相关的。然而在实际应用中, 这一点 $Cov(x, u) = 0$ 未必成立。

而工具变量提供了一个解决内生性问题的思路: 找一个“替身”来代替内生的解释变量 x , 这个“替身”本身与误差项 u 无关, 但能通过 x 间接影响 y 。

12.2 回归模型

一个有效的工具变量 z 需要满足以下两个条件：

- 相关性

z 必须与被解释的变量 x 相关，也即 $Cov(z, x) \neq 0$ ；实际中相关性越强通常越好

- 外生性/排他性约束

z 必须与误差项 u 不相关，即 $Cov(z, u) = 0$

直观而言， z 只能通过影响 x 来影响 y ，而不能通过其他任何途径直接影响 y ，也不能与模型中影响 y 的其他遗漏变量相关，这通常是最重要也最难满足的条件。

根据以上两个假定，容易得到估计量：

由 $y = \beta_0 + \beta_1 x + u$ ，两边同时对 z 取协方差，得

$$\begin{aligned} Cov(y, z) &= \beta_1 Cov(x, z) + Cov(u, z) \\ &\Rightarrow \\ \hat{\beta}_1 &= \frac{Cov(y, z)}{Cov(x, z)} = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z})} \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned}$$

对于高维情形，可以类似得到

$$\hat{\beta} = (Z'X)^{-1}Z'Y$$

IV 估计量也可以通过两阶段最小二乘法来得到——2SLS

- 一阶段

对模型 $x = \pi_0 + \pi_1 z + v$ 回归，得到 x 的预测值 $\hat{x}$ ，由工具变量的假定，它与 u 是无关的

- 二阶段

对模型 $y = \beta_0 + \beta_1 \hat{x} + e$ 回归

12.3 统计性质

在同方差 $\mathbb{E}(u^2|z) = \sigma^2$ 的假定下，可以得到 $\hat{\beta}_1$ 的渐进方差为

$$AVar(\hat{\beta}_1) = \frac{\sigma^2}{n\sigma_x^2\rho_{x,z}^2}$$

实际中，方差可采用以下估计量

$$\frac{\hat{\sigma}^2}{SST_x \cdot R_{x,z}^2}$$

其中， $\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2$

记 $SE(\hat{\beta}) = \sqrt{\frac{\hat{\sigma}^2}{SST_x \cdot R_{x,z}^2}}$ ，取 $x = z$ 则得到 OLS 情形的标准误

由 $R_{x,z}^2 \leq 1$ 易知

$$SE_{IV}(\hat{\beta}) \geq SE_{OLS}(\hat{\beta})$$

12.4 工具变量的优良

容易得到

$$\begin{aligned} \text{plim} \hat{\beta}_{1,IV} &= \beta_1 + \frac{\rho_{z,u}}{\rho_{z,x}} \frac{\sigma_u}{\sigma_x} \\ \text{plim} \hat{\beta}_{1,OLS} &= \beta_1 + \rho_{x,u} \frac{\sigma_u}{\sigma_x} \end{aligned}$$

一个 IV 是无效 (invalid) 的, 若 $Cov(z, u) \neq 0$

一个 IV 被称作 weak IV, 若 $Cov(z, x)$ 接近 0; 若恰为 0, 则相关性条件失效, 模型未被识别 weak IV 可能带来以下问题:

- 估计系数的标准误很大
- 在小样本的条件下, 估计系数可能是有偏的
- 如果 z, u 有微弱的关系, 也可能导致很大的偏误

12.5 多元回归中的工具变量

以下述模型为例 (下式称作**结构式**)

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u_1$$

假定 z_1, z_2 是 IV, 满足

$$\mathbb{E}(u_1) = 0, Cov(z_1, u_1) = 0, Cov(z_2, u_1) = 0$$

我们可以根据矩条件得到估计应满足的方程组

$$\begin{aligned} \sum_{i=1}^n (y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) &= 0 \\ \sum_{i=1}^n (z_{i1} - \bar{z}_1)(y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) &= 0 \\ \sum_{i=1}^n (z_{i2} - \bar{z}_2)(y_{i1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i2} - \hat{\beta}_2 z_{i1}) &= 0 \end{aligned}$$

其余模型可类似得到估计

12.6 矩阵版本的 IV

12.6.1 基本模型与假设

考虑线性模型:

$$Y = X^\top \beta + e = X_1^\top \beta_1 + X_2^\top \beta_2 + e$$

其中: - X_1 : $k_1 \times 1$ **外生变量** ($E[X_1 e] = 0$) - X_2 : $k_2 \times 1$ **内生变量** ($E[X_2 e] \neq 0$) - $k = k_1 + k_2$ 为总变量维度

工具变量 Z ($l \times 1$) 需满足: 1. **外生性**: $E[Z e] = 0$ 2. **满秩**: $E[Z Z^\top] > 0$ (正定) 3. **相关性**: $\text{rank}(E[Z X^\top]) = k$ (关键识别条件)

12.6.2 工具变量构造

$$Z = \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} = \begin{pmatrix} X_1 \\ Z_2 \end{pmatrix}$$

- $Z_1 = X_1$ (模型内已知外生变量) - Z_2 : 额外外生变量 (l_2 维) - $l = k_1 + l_2$ (工具总数)

识别情形: - $l = k$: 恰好识别 - $l > k$: 过度识别

12.6.3 估计量推导

- IV 估计量 (恰好识别)

由矩条件 $E[Z(Y - X^\top \beta)] = 0$ 得:

$$E[ZY] = E[ZX^\top] \beta$$

样本估计量:

$$\hat{\beta}_{IV} = \left(\sum_{i=1}^n Z_i X_i^\top \right)^{-1} \left(\sum_{i=1}^n Z_i Y_i \right)$$

矩阵形式 ($Z_{n \times l}, X_{n \times k}, Y_{n \times 1}$):

$$\hat{\beta}_{IV} = (Z^\top X)^{-1} Z^\top Y$$

- 2SLS 估计量 (过度识别)

两阶段过程: 1. 第一阶段: X 对 Z 回归 $\rightarrow \hat{X} = Z(Z^\top Z)^{-1} Z^\top X$ 2. 第二阶段: Y 对 $\hat{X}$ 回归
估计量公式:

$$\hat{\beta}_{2SLS} = \left(X^\top Z (Z^\top Z)^{-1} Z^\top X \right)^{-1} X^\top Z (Z^\top Z)^{-1} Z^\top Y$$

重要性质:

$$l = k \implies \hat{\beta}_{2SLS} = \hat{\beta}_{IV}$$

关键注意事项

1. 标准误估计:

- 禁止直接使用二阶段回归标准误 (低估真实误差)
- 正确做法: 专用命令 (如 `ivregress`) 计算

2. 弱工具变量问题:

- 诊断: 一阶段回归 $F > 10$ (单工具情形)
- 风险: 弱工具可能导致 IV 估计比 OLS 更差

3. 效率比较:

$$\text{Avar}[\sqrt{n}(\hat{\beta}_{IV})] \geq \text{Avar}[\sqrt{n}(\hat{\beta}_{OLS})]$$

- 当 X 外生时, OLS 更有效

重要公式

概念	公式
矩条件	$E[Z(Y - X^\top \beta)] = 0$
IV 估计量	$\hat{\beta}_{IV} = (Z^\top X)^{-1} Z^\top Y$
2SLS 估计量	$\hat{\beta}_{2SLS} = (X^\top P_Z X)^{-1} X^\top P_Z Y$
投影矩阵	$P_Z = Z(Z^\top Z)^{-1} Z^\top$
方差比 (IV vs OLS)	$\frac{\text{Avar}_{IV}}{\text{Avar}_{OLS}} \approx \frac{1}{R_{x,z}^2}$